美国居民通胀预期的Agent模拟

基于SCE的历史重建与机制检验

给定家庭处境、接触的信息与原有信念，
能否同时重建总体预期和家庭之间的差异?

当前阶段

已完成真实模拟及十二期扩大验证。
工程流程已贯通，稳定超越基线的行为机制仍在研究。

水上挽月 · 复旦大学 · 2026年10月19日

SCE：纽约联储的消费者预期调查

研究的是居民对未来12个月物价变化的判断，不是直接预测下一月实际CPI。

调查制度	具体情况
调查机构	美国纽约联邦储备银行（纽约联储）
频率与起点	2013年6月启动，每月在线调查，月内分周收集
对象与规模	约1,200名家庭户主；涉及家庭财务决策
同一人参与多久	轮换面板，最多12个月；每月有人退出和加入
公开时间	月度汇总通常次月公布；核心微观资料滞后9个月
本项目研究的题目	Q8点预期；Q9十档概率，均针对未来12个月

为什么选择SCE

通胀预期影响消费、工资判断和政策传导。

公开逐人概率回答和跨月记录，可以检验家庭差异及信念更新。

总体指标和微观结构可以相互校验。

真实调查每月约千人；本项目的192人是实验抽样规模，不是SCE调查本身的规模。

来源：纽约联储SCE FAQ（2026-10-19核查）；微观资料与问卷。

历史重建与未来预测的研究边界

当前主要结果属于A线：给定真实回访者画像与过去信念，重建本期回答。

比较维度	A 历史重建	B 未来预测
研究问题	已知历史条件下，能否还原该月回答与分布？	在结果公布前，能否预测下一期调查？
人口与原有信念	可用后来公开的真实画像、本人过去问卷	只用截止前可得旧人口、合成人口与可用历史
信息范围	可声明事后重建条件；现实验仍按历史窗口截断E	人口、E、参数和模型时间边界均须符合事前条件
目前完成情况	已完成多轮条件模拟和十二期检验	新加入者初始化、信念递推和误差累积尚未验收

当前每个月补入真人上期回答，不能称为Agent连续十二个月自主预测。

A也需要独立检验；若使用某项历史结果作校准，就不能再用同一项证明预测成功。

项目A/B安排、十二期冻结协议；本期目标通胀答案只进评价层。

项目架构与各环节进度

研究遵循B=f(P,E)：居民处境与信息环境共同影响回答；模型如何理解信息也需要检验。

研究环节	已经实现	主要缺口
Literature / Study	价格体验、信念更新等综述；A/B边界与对照	理论需转成可检验机制
Population	真实画像、本人历史、CE与信心合成	新入组者与合成属性的联合关系
Environment / Dataset	价格、新闻、政策归档；106个月微观资料	个人实际接触与历史版本证据
Simulation / Trajectory	官方引擎真实LLM运行；保存消息、失败和用量	尚未形成稳定优于基线的配置
Analysis	同支持评价、分组、跨期与过去信息基线	独立月份检验与B路线递推
Reports	开题已提交，实验台账与复算入口齐备	最终研究报告、研究包和演示

流程能够运行和结果有效是两个标准：工程基础已具备，经验有效性仍是当前重点。

来源：项目总纲、实验流程与当前配置；官方SocioVerse2引擎＋本项目准备和评价模块。

居民画像、原有信念与合成补充

当前从SCE真实回访者中抽样；真实测量与外部合成字段分别标记。

信息层	当前输入	设计目的及限制
实测人口特征	年龄组、教育、收入档、地区/州、住房、就业、数理标签	刻画家庭处境；标签不等于行为已真实实现
本人过去信念	真实上期Q8点值和Q9十档；更早均值与有效次数	保留个人位置；短历史与无历史者需另设规则
合成消费结构	按外部CE同类家庭分配四类支出占比	提供生活背景；不是该受访者的真实购物篮子
合成美联储信心	依据外部调查分布分配的态度标签	描述政策理解背景；不能视为本人已测信任

十二期采用年龄×收入分层；评价使用调查权重÷入样概率。模型不接收原始ID、权重或本期通胀答案。

当前实验覆盖有上期回答的回访者，不能直接代表新加入者或全国全部家庭。

来源：SCE原问卷和微观资料、CE供体、Gallup信心分布；合成字段不是本人实测。

从公共资料到每个家庭接触的信息

参考输入包含公开价格、趋势、政策及新闻；“信息已公开”仍不等于“每个人都看过并理解”。

组成	当前做法	需要改进的地方
价格与趋势	CPI、就业、汽油等；保留单位、参考期和发布日	完整统计表可能让不同家庭都获得同样宏观信号
新闻	粗筛＋LLM分类；标题和摘要，重复文本只呈现一次	NYT不是所有居民实际使用的媒体；主题覆盖不均
个体分配	参考为3篇共同新闻＋5篇个人新闻；50/50混合抽取	50/50是抽取概率，不是每人恰好一半相关新闻
时间与版本	通常截至目标月CPI首发日当天结束（纽约时间）	这是月中参照截点，不等于每位真人的作答日

USTR贸易与消费者处境资料已做小试；Google Trends、Household Pulse等仍需核可得性与历史版本。

下一步重点不是继续增加资料总量，而是检验家庭角色如何改变接触的类别和详细程度。

来源：BLS首发稿、EIA汽油、NYT Archive、政策事实和Event MCP核查。

Agent收到什么，如何形成问卷回答

以下为压缩示意，所有数字均为虚构值；实际运行使用完整问卷和冻结消息。

输入示意

你的处境：40–59岁、大学教育、租房、全职就业。

原有信念：上月点预期4%；同时保留上月十档概率。

更早记录：已回答5次，历史平均预期约3.5%。

本期信息：截至指定日已发布的价格趋势、政策和8篇新闻。

这是你原有的判断；可结合后来获得的信息调整，也可保持。

输出要求

Q8：未来12个月物价变化的点预测。

Q9：向10个通胀/通缩区间分配概率，非负、合计100%。

直接填写本期答案；不让模型提交概率差值。

保留先验并不等于模型会充分保留个人差异；它实际如何使用输入，要看对照结果。

依据实际提示结构改写示意；示意值不是真人记录，不是新增模拟结果。

真实运行规模与可复现记录

核心模拟使用官方SocioVerse2引擎；本项目开发输入准备、机制适配、计分和评价。

已执行批次	规模与覆盖	实际执行
十二期扩大验证	2020—2025每年2个月；192人/月；生成2遍	4,608请求；4,606有效；估$5.155；约24分钟
六期新闻量对照	6个月×96人；3组；各生成2遍	3,456请求；3,454有效；估$3.860；约19分钟
其他机制小试	先验、认知、财务、心理、经历、价格信息等	按各批同样本对照解释，不把不同批次拼成成绩

共同运行设置

DeepSeek官方Flash；温度0.5，关闭思考，无自动重试。保存输入、原始回复、非法回答、种子、模型回包指纹与用量。可复用已有轨迹重算，无需再次付费。

当前模型为可变别名：记录实际回包和指纹，不将别名等同于永久固定的模型版本。

来源：十二期执行收据、六期新闻量执行记录；费用为token估算，非独立账单。

评价总体水平、家庭差异和跨月变化

主指标始终与同一批真人、同一月份及同一权重比较；Q8与Q9分别报告。

评价对象	指标及直观含义	比较基准
总体预期水平	中位数MAE（pp）；越低越好，先逐月算误差再平均	当前A线：照抄同一本人上期问卷
家庭之间的差异	W1：整条分布相距多远；IQR：中间一半人的跨度	同样本真人分布；IQR不是越大越好
同一个人的变化	更新分布距离、变化方向、保持比例、秩序保留	对应真人相邻月变化
个人主观不确定性	一个人Q9内部的概率宽度、零值和刻度	区别于跨人分歧；不与人际IQR混用

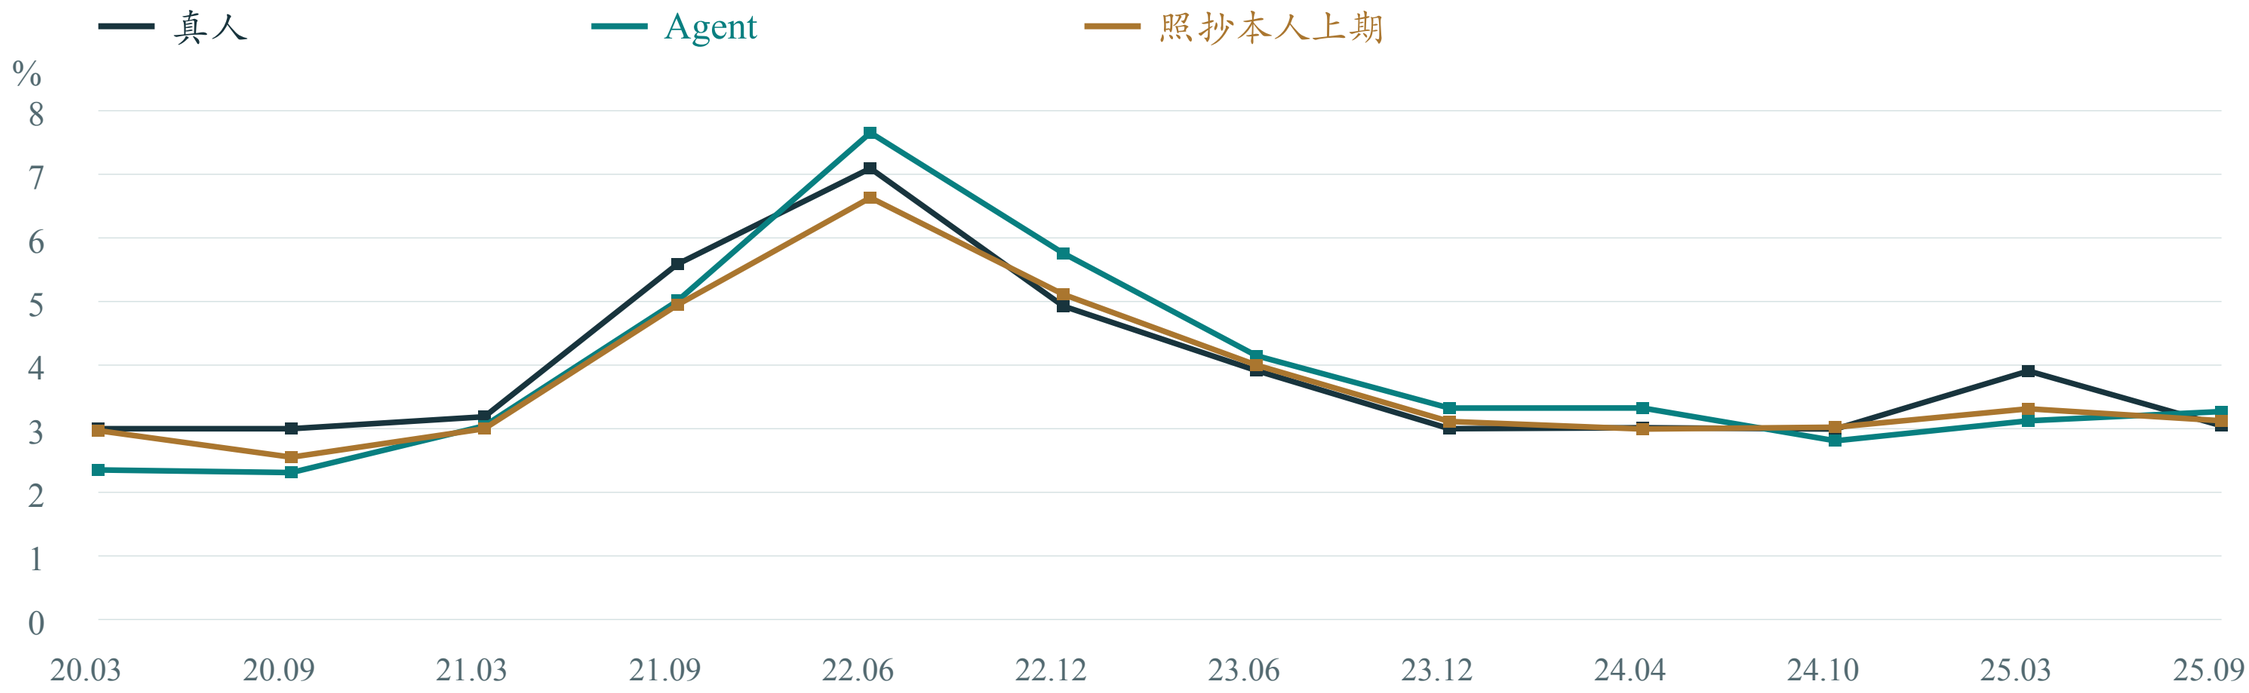
Q9用同一冻结近似计分器；分位数采用加权经验CDF左逆。它与官方插值中位数及headline不完全相同。

总体接近是有效性的门槛；还原微观差异与更新，才是Agent方法需要另外证明的价值。

统一评价口径：个人Q9密度均值→跨人设计加权中位数→逐月/遍绝对误差→等权平均。

十二期扩大验证：仍未稳定优于持续性基线

每期192人、两遍生成；主口径是模型与同一批真人Q9中心的差距。



全部12期 MAE：Agent 0.459 / 照抄 0.239 pp

新增8期：0.539 / 0.277 pp

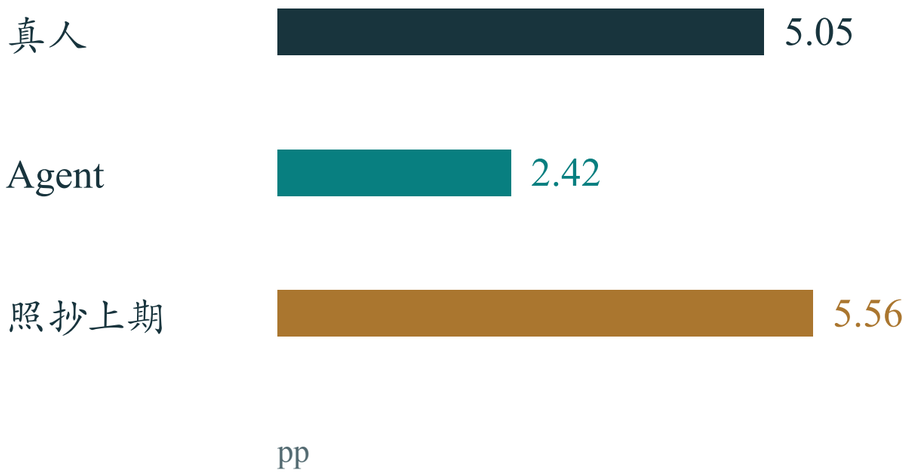
旧4期扩大人数后MAE为0.300；主要退步来自新增时期，说明早期好结果未稳定推广。

来源：2026-10-17十二期冻结评价。图为两遍中心均值；MAE先逐遍计算，不由均值曲线重算。

微观差距：个人差异被压缩，更新对象没有区分好

十二期诊断发现：真人基本保持时模型常改动；真人大幅调整时模型又改得不够。

跨人的预期跨度（IQR）



相对上月的平均绝对变化（pp）

真人事后分组	真人	Agent
基本保持（≤0.5pp）	0.117	2.553
上调者	4.368	2.346
下调者	4.567	2.602

十二期分布W1：Agent 2.434，照抄0.873pp。共同中心接近不能掩盖完整分布仍有较大差距。

不能用本期真人属于哪组来选择预测方法；需要检验过去资料能否事前区分保持和更新。

来源：十二期主评价及2026-10-18回复差距诊断；按本期真实变化分组，仅用于事后定位。

机制实验的收获与取舍

沿用某项配置不代表它已单独验证有效；不同批次的最低误差不能相加。

方向	得到的信息	当前处理
本人过去信念、时间说明	部分改善水平或分布；个人位置仍保留不足	保留A线工作参考，继续检验持续性
政策事实＋合成央行信心	早期四期中心误差有下降，微观差异仍小	保留参考；合成态度非本人实测
数理实答、Q1/Q2财务信息	局部人群或指标改善，未形成跨期整体收益	不叠加为默认；保留得失与复算
心理、历史经历、频率说明	现有匹配/文字注入未稳定改善主指标	暂缓实现；不否定机制本身
概率映射、差值作答	取整改善外观；差值出现大量非法概率	默认直接回答，不以格式改善冒充拟合成功

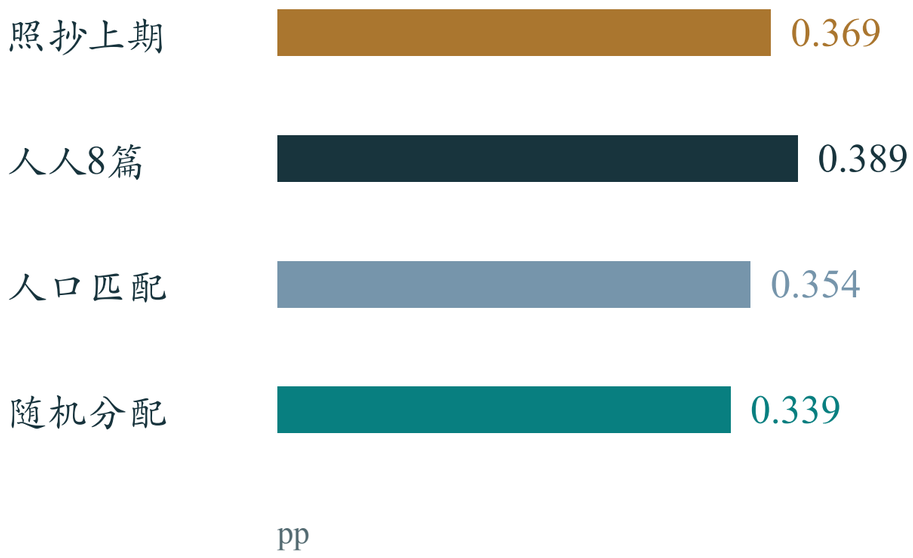
目前较清楚的经验是：增加标签和更多背景，不能自动恢复个人经历、信念与信息的真实关系。

来源：实验台账；原有各批真实对照及后续跨月复查，详附录配置和证据。

差异化新闻量：有积极信号，人口匹配未显示增量

六期96人、三组各两遍。随机和人口匹配使用相同3/8/20篇名额：48/28/20人。

同支持群体中位数MAE



如何理解结果

随机组0.339pp，低于同批照抄0.369；但只在3/6个月胜出，去掉部分月份后优势反转。

人口匹配0.354，未胜随机；分布W1和人际跨度没有同步改善，未通过预登记筛选。

完整统计表可能绕过新闻接触差异；这是待检解释。

保留随机新闻量作验证候选；六期0.339不能替换十二期0.459，二者样本、时期与配置不同。

来源：2026-10-19新闻量试验；571共同人月。六期为已探索月份，不称独立盲测。

真人行为研究：为机制设计提供经验约束

Kimi基于2017—2025微观资料完成初步分析；本轮只引用交付，不复跑、不作独立验证。

初步观察	报告中的量级	设计启发
有一部分人保持原答	十档完全不变：加权约15.4%	保留保持的可能，不要求每期必须调整
变动有长尾	变动者绝对变化均值：加权约3.34pp	不能只用小幅、对称扰动代替所有更新
概率表达较粗	非零概率约81%为5的倍数（非加权）	报告习惯需单列，但取整不是全部解释
个人位置有持续性	至少6个有效月者，奇偶波个人均值相关约0.85	保留持久个人状态，避免每月重新抽一个人

这些是问卷层面的规律，可能混合真实信念、重复填法和测量误差；不能直接命名为注意力或心理因果参数。

F3a负斜率的经济解释、F3b的OLS/IV差异和类型分配，先列复核，不直接用于参数校准。

来源：Kimi 2026-10-19报告与汇总；相邻月有效对103,630。以下为待复核的描述性发现。

下一项重点：家庭采购角色与可见价格信息

先把“谁接触哪些信息”做成可核查的对照，再判断它能否改善水平和微观分布。

传导路径

家庭结构
年龄、全住所人数、儿童状态

→

采购承担程度
按ATUS同类家庭概率合成

→

可见价格信息
调整食品/日用品的类别与细节

→

未来12个月
通胀预期

已完成：六期576人月家庭核查，94.6%有可用过去家庭构成；采购角色与信息菜单原型已备。

下一步：核食品和日用品资料，固定新闻条件，比较角色匹配与同月打乱；避免完整宏观表掩盖个人菜单差异。

这是跨调查概率合成，不是识别出本人真实购物角色；宏观分类CPI也不冒充本人购物收据。

依据：D’Acunto等JPE/PNAS（2021）价格接触与采购分工研究；ATUS—SCE原型尚未模拟。

后续研究与需要讨论的问题

在最终交付前，优先完成一个有依据的机制对照，并保留完整的有效与无效结果。

顺序	具体工作	完成标准
1 收束已有证据	复核Kimi关键解释；补角色—价格输入与未知处理	理论路径与资料范围清楚，不直接套回归系数
2 固定一项对照	角色匹配/打乱，冻结月份、种子、模型及评价	先干跑；真实调用另确认范围和预算
3 独立验证	在未参与该机制调整的时期检验中心与分布	同支持胜基线，报告区间和分组局限
4 最终交付	研究报告、研究包、演示；B可执行性单独验收	明确时间边界、许可、实际成本与复现入口

希望讨论　如何提高相对过去信念的新信息增量？怎样区分真实信念与报告习惯？在时间约束下，哪项机制最值得验证？

若新机制仍不能稳定改善，应报告其失效边界与可复现证据，不将局部最低误差包装为成功。

工作顺序，非新付费授权；最终提交：2026-10-31 23:59北京时间，依据用户提供的组委会邮件。

关键实验配置与实际采用范围

“参考配置”用于保持各次对照可比，不表示其中每个模块都已单独证明有效。

项目	十二期参考验证	六期新闻接触对照
月份	2020-03/09；2021-03/09；2022-06/12； 2023-06/12；2024-04/10；2025-03/09	2020-09；2021-09；2022-06； 2023-12；2024-10；2025-03
规模	192人/月；1组×2遍；4,608请求	96人/月；3组×2遍；3,456请求
抽样和评价	年龄×收入分层；调查权重÷入样概率	固定旧样本，同支持按设计权重评价
信息差异	3篇共同＋5篇个人新闻；完整统计	3/8/20篇；仍保留完整统计；未加ATUS角色
共同参数	Flash、温度0.5、关闭思考、无重试	Flash、温度0.5、关闭思考、无重试
有效率/模拟费用	4,606/4,608；约$5.155	3,454/3,456；约$3.860

生成两遍衡量输出随机性，不等于独立受访者翻倍；已外推的Normal人口也不算新增独立LLM样本。

来源：12期执行收据、6期新闻量协议、当前配置；所有费用均为token估算。

Q8/Q9口径、比较对象与复现

Q8是点回答；Q9拟合个人连续密度后取均值。两者不能简单混合或互换。

口径问题	本项目处理
Q9如何形成总体中心	合法十档→同一冻结近似拟合→个人密度均值→设计加权中位数
MAE如何跨期汇总	逐月、逐遍先算绝对误差，再对月份/遍等权平均；单位pp
同支持与全国波次	12期同支持2,284/2,304人月；全国完整波次另报，不混用
官方headline的差异	近似数值拟合及经验CDF左逆，不宣称完全复刻官方插值统计
基线与后处理	A用本人上期；B用截止前最后公开指标；加权组合另列校准结果
失败和复现	无效回答保留；固定种子、输入/代码哈希；旧轨迹可零API重算

不按测试答案挑权重、月份、种子或成功指标；探索性结果与独立验证分别报告。

来源：SCE原问卷与FAQ、冻结计分器、统一评价协议、十二期共同支持记录。

Kimi六项发现与待复核内容

本页记录合作交付，不表示Codex已复算或认可所有解释；机制参数暂不据此冻结。

发现	交付结果 / 覆盖	后续核查
F1 / F2 保持与变动	约15%完全保持；变动幅度有长尾	阈值、权重、取整与真实更新分别解释
F3a 误差—修正回归	报告斜率−0.483；2017-02至2023-02	共享误差项、预测窗口和固定效应；补CPI是否必要
F3b 均值回归	报告OLS约−0.43、IV约−0.05	工具有效性未定；两估计不能当可信区间端点
F4 概率刻度	非零格约81%为5的倍数（非加权）	区分格子与人；刻度映射不等于恢复信念
F5 持续差异	奇偶波个人均值相关约0.85	有限波次、选择样本与报告习惯的影响
F6 行为类型	按更新频率、幅度和长期水平做聚类	探索性分类；须防全期信息回填及校准过拟合

负斜率不能单独证明居民过度反应；OLS/IV差异也不能直接决定均值回归的校准强度。

来源：Kimi 2026-10-19 README及analysis_summary；103,630相邻月有效对，具体子样本各不相同。

资料依据与最终交付要求

围绕社会科学价值、方法严谨性、可信结果及可复现工程组织报告。

组委会关注点	目前已覆盖	最终还需落实
时间边界与模型知识	历史发布日期、版本与知识诊断记录	固定开发/验证/预测月；真值隔离与预测封存
人群与跨期规则	分层权重、CE匹配、真实上期信念	Core/Normal扩展、新入组者与B自递推
评价与基线	Q8/Q9分列；MAE、W1、IQR和分组诊断	独立时期、公平信息基线和稀疏组规则
运行与可复现	官方引擎、种子/轨迹、干跑和旧轨迹重算	全项目调用/成本/耗时台账、干净环境验收
许可与发布范围	原始微观不进Git；聚合证据可追溯	核各源许可；新闻/汽油历史版本未知则排除严格B

资料：纽约联储SCE、BLS/CE/ATUS；价格体验、经验学习、信息更新文献与ConsumerSim；各批冻结协议和聚合结果。

现有模型未稳定贴合历史SCE或未来CPI；这不能证明预训练知识无影响，严格预测仍需时间证据或事前封存。

来源：赛事官网已归档评分；用户提供的资助反馈邮件（2026-10-15）；原始来源详HTML资料链接。