居民通胀预期的智能体重建

机制依据、设计选择与跨时期评估

水上挽月 · SocioVerse Challenge 2026 · 赛道A：历史重建与未来预测

研究报告初稿 v0.4 · 2026-10-25

居民通胀预期既有持续性，也随生活价格和公共信息而变。我们在SocioVerse2的P/E/B框架下，以纽约联储消费者预期调查（SCE）为对象，将人口构成、信息接触和既有信念转化为可检验设计。经人口维度筛选与受控比较，形成54格分层样本，每月512名LLM智能体回答点预期与概率问卷。2019年1月至2025年10月的历史重建，全国中心MAE为0.317个百分点，持续性基线为0.223；2025年11月至2026年9月改用滞后画像与合成先验的时点回测，分别为0.241和0.173。两段均有局部收益，但尚未稳定超越基线，人际分歧仍有收缩。本文结合理论依据、实验取舍与失败时期，检验生成式社会模拟在调查重建中的经验有效性。

关键词：通胀预期；生成式社会模拟；异质家庭；信息接触；概率问卷

1 研究问题与理论框架

家庭怎样看待未来物价，会影响消费、储蓄和工资判断，也是政策沟通的重要问题。只拟合一条全国曲线，却可能掩盖微观机制的错误：高预期与低预期家庭的偏差可以互相抵消，缺乏个人差异的模型也可能碰巧得到正确中位数。我们把人群P（家庭背景与既有状态）、环境E（可见信息）和行为B（问卷回答）分开，因此同时研究总体中心、家庭之间的分歧，以及同一家庭如何修订判断。

1.1 SCE调查的研究价值

SCE由纽约联储开展，自2013年起按月调查美国户主。官网FAQ目前表述约1,200人，采用全国代表性的线上轮换面板；受访者最多连续参与12个月，答卷分布在当月各周。全国摘要按月发布，核心微观资料约滞后9个月公开。[1,2] 它既能追踪个人更新，又同时询问点判断和概率分布，适合检验“平均看起来合理，个人行为却不相似”的问题。本文预测的是居民对未来12个月通胀的看法，并非把实际CPI当成调查答案。

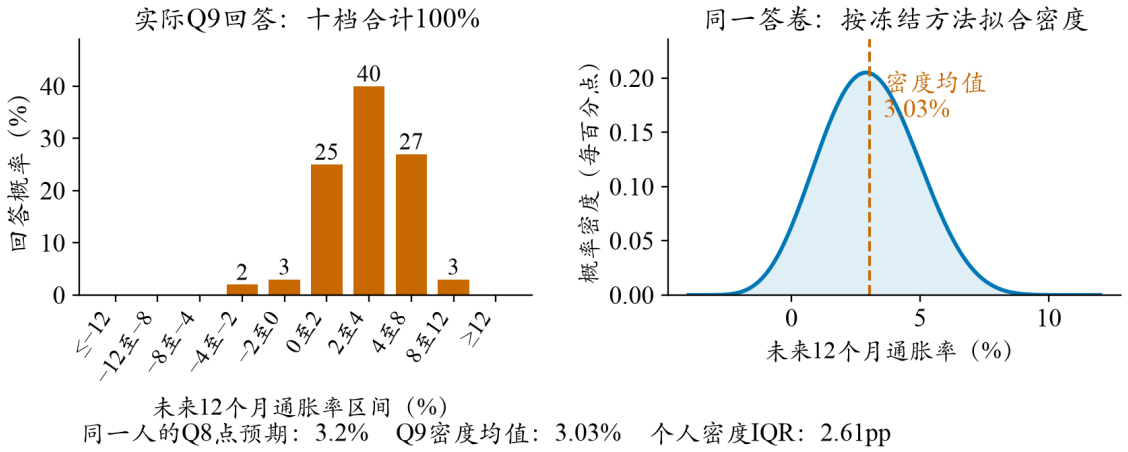
1.2 从理论依据到机制假设

理论线索	对预期形成的启发	本项目可检验的设计
信息更新有成本[4]	公开信息不等于人人接触、理解和吸收；旧信念可能持续。	保留真实历史，允许保持或更新；分别检验新闻数量与主题。
生活价格具有显著性[5]	购买中反复接触的涨价可能比支出占比更能影响判断。	从家庭结构匹配采购角色，再改变可见价格，设置打乱对照。
经历与认知存在差异[9]	经历的时间长度、数理理解和资源约束可能塑造不同响应。	先用真人数据筛选人口维度，再检验认知/财务信息能否改变模型。

这些文献提供的是传导方向，而不是可直接套用的个人更新系数。我们的研究策略是先把每条理论路径变成明确的输入差异，再用对照实验判断模型是否真的使用了这些信息。ConsumerSim提供了人口、环境、回答和惯性校准分层比较的参照；本项目进一步利用SCE微观答卷，检查聚合拟合之外的行为结构。[3]

2 SCE问卷与指标构建

两道题都面向未来12个月，却记录不同层面的判断。Q8询问预计通胀或通缩的幅度，是一个点预期；Q9要求为十个可能区间分配概率，表达未来涨幅的不确定性。图1展示2025年6月一位实际受访者的答卷：Q8为3.2%，Q9则把40%的概率分配给2—4%，27%给4—8%，25%给0—2%，其余概率落在其他区间。两题来自同一人，点判断和密度均值不必完全一致。



来源：SCE 2025年6月公开微观答卷；单个受访者示例，不代表当月总体。

图1 真实SCE答卷及其密度转换。来源为2025年6月公开微观资料，左侧为原始十档概率，右侧按本项目冻结算法拟合，密度均值3.03%、个人密度IQR为2.61pp。仅展示一位受访者，不代表当月总体；未展示身份或人口特征。

2.1 从十档概率到个人密度，再到人群中位数

每档概率须在0—100%之间，合计100%；负的通胀预期合法，负的概率不合法。按照SCE方法的研究复现，单个闭区间用均匀分布，两个相邻正概率区间用三角分布，至少三个正概率档拟合广义Beta密度。Beta参数通过带约束最小二乘，使有效档界的累计概率尽量贴近回答。随后取每人密度的均值μ，而不是先把所有人的十档概率平均。最后将这些个人均值按人口权重排序，累计权重首次达到50%的位置，就是本项目的群体中位数。

这样就区分了两种“宽度”：一位受访者的密度IQR反映他对未来有多不确定；不同受访者的密度均值IQR反映人群有多大分歧。两者可以朝不同方向变化。官方概念同样先取个人密度均值，但本项目冻结的近似拟合和经验CDF左逆分位数并不等于官方全部优化及插值细节，因此另列官方全国值与同支持微观比较。[1,2]

评测问题	采用指标	怎样理解
总体中心准不准	MAE、RMSE、bias，单位为百分点（pp）。	MAE看平均绝对偏差；RMSE更重视大偏差；bias区分偏高或偏低。
结构是否相似	跨人W1、跨人IQR、个人密度IQR。	W1是两条分位数曲线距离的面积；IQR=P75−P25，应与真人对照，不是越大越好。
是否在正确的人身上更新	相对本人真实上期的变化W1、保持率、大变化率及分组误差。	让模型产生更多变化，并不保证它能识别谁会改变、谁会保持。

3 人口分层的统计依据

若只按少数粗特征抽样，可能遗漏重要群体；若把所有人口字段交叉，小格又会缺乏支持。我们因此把“对回答有多少独立信息”和“能否获得可靠支持”分开判断。使用98,382个历史人月构成的框架，从学历、数理、收入、年龄、就业、性别、住房和地区八项中比较126套三/四维候选；监督分析在八项已知且答卷有效的95,375人月共同支持上进行。

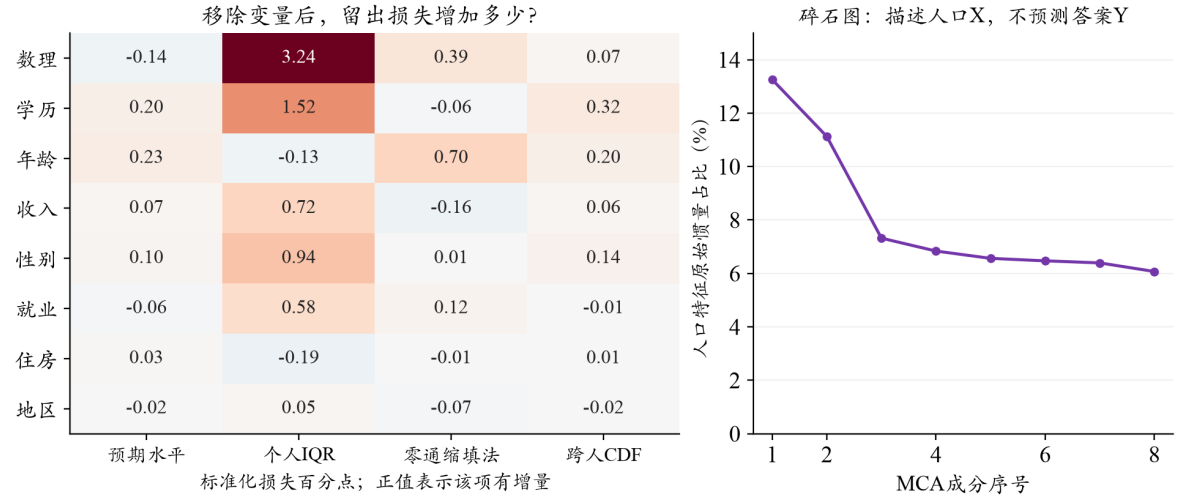


图2 既有统计证据。左：2019—2022年按受访者四折留出，移除一整项特征并重新拟合后的损失变化（标准化损失百分点，非通胀pp）。右：分类变量MCA碎石图，只描述人口X的共变，不能当作问卷Y的解释率。

左图显示，数理与学历对个人不确定性较有增量，年龄更多关联预期水平和零通缩填法，各变量的用途并不相同。我们同时检查了冗余：学历—数理的加权Cramer V约0.317，整块调整GVIF仅1.007—1.186，没有证据需要因严重共线性机械删除其中一项。MCA帮助描述结构，最终取舍仍以留出表现和抽样支持为依据。

3.1 维度选择与有限样本下的代表性

四领域等权评分涵盖个人均值、密度IQR、零通缩填法和均值CDF；它衡量月内异质性，不是全国MAE。相对无人群差异参照，旧“学历×在职”六格的平均标准化损失改善为2.160%，学历×数理×年龄×收入为4.917%；后两段时间检查为5.413%和5.471%。原较严支持约定偏向更省样本的“学历×数理×性别”12格，但年龄和收入也提供资源与经历维度。允许小格过采样后，我们据此选择四维54格，而不是把12格或碎石图的某个拐点视为唯一答案。

实际分类为学历3档、数理高/低、年龄＜40/40—60/＞60、年家庭收入＜5万/5—10万/＞10万美元；未知另池。每月抽512人，非空格尽量保底8人，小格全取，余额按人口质量分配。固定种子20261023按人无放回排序，不读取本期预期；设计权重w/π再在格内校准，使过采样的小格汇总时回到其真实人口比例。82个月均可分配，格质量误差＜1e-12，但512人方案只有约60%的质量落在格内ESS≥10的格，不能把覆盖当作精度保证。 就业、住房与地区仍进入画像，不因未列为网格坐标而删除；调查权重和原始身份不发给模型。

3.2 分层画像与个人历史的结合

同类家庭内部仍可能有不同习惯与经历。因此，网格只决定抽样和分组，模型仍读取本人更早的Q8/Q9及历史摘要。没有历史者从最近1—3个月同类匿名新/老受访者池取得联合起点，并保留合成标签；本期答案不参与匹配。新人同样由LLM作答，不用Normal复制来填补身份信息。

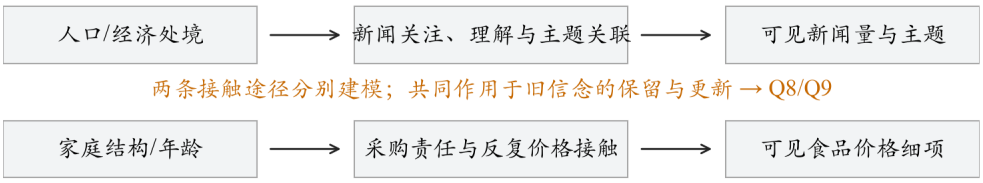
3.3 样本加权与近期人口来源

A、B两段都由每月512人直接调用LLM，没有Core＋Normal贝叶斯扩展，也不把其余人复制成新答卷。代表性由抽样权重承担：在格h内，先按原调查权重除以入选概率π，再乘校准系数，使各格权重质量恢复源人口比例；经验CDF按权重而非人数累计，达到50%处取中位数。权重可以是非整数，扩成约1,300个标签并不会凭空增加信息。

A以历史当月人口为源，缺历史者才匹配近期联合供体。B受微观披露滞后约束，按“源调查月末加九个日历月且早于截止”的推定规则逐月取源，2025-11用2025-01，推进至2026-08/09用2025-10；精确历史字节版本尚未认证。B权重代表相应旧源，而非已知近期真实人口；就业、收入随源记录，不额外宏观修正。合成Q8/Q9保持供体联合答卷，分配后仅将历史Q9中心校准到当时已公开全国值±0.05pp。此步骤是初始化，不是扩样；Q8不强加Q9锚。

4 信息接触机制与实验设计

有限注意力意味着“公开可得”与“本人接触”之间还有选择过程。SCE专项研究发现，学历、收入及年龄与宏观关注有关，但关系依主题而变，通胀关注回归的伪R^2仅0.027。[10] 这不能换算成个人阅读篇数，却提醒我们保留大量组内差异：高学历不等于一定看很多新闻，经常采购也不等于经常读财经报道。



文献提供传导动机；CE/ATUS与关注资料仅提供代理分配，不等于本人真实接触记录。

图3 理论路径与操作化。新闻与购物价格是两种信息接触；本人旧信念另行保留。箭头表示待检验的机制路径，不是本文已识别的因果系数。

我们把数量、主题、理解分开：用3/8/20篇表示消息广度，分别约占50%、29.17%、20.83%，整月平均8篇；以同月分配打乱区分“异质性本身”与“人口匹配”的增量。另一方面，CE 2020提供合成支出，ATUS 2022按年龄、住所人数和儿童状态提供采购角色概率，再决定食品细项的可见程度。它们是代理匹配，不是本人的阅读记录、购物收据或心理实测。

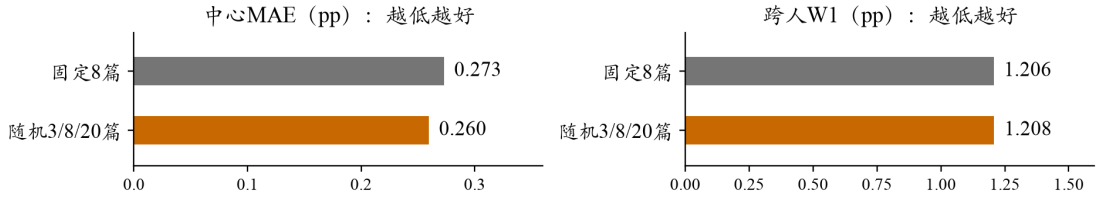


图4 V3.2八期新闻量对照的直接两组共同支持，1,116人月、两遍生成。随机量中心略改善，W1几乎不变；3/8/20的篇数与比例是可比成本下的实验设定，并非文献估计的真实阅读量。

理论依据	对照设计	证据与取舍
旧信念具有持续性	明确个人起点与时序；另比较固定半程更新指导。	Flash先验表达使W1 2.617→2.329，中心未同步改善；保留状态，不规定固定更新幅度。
认知与财务处境可能改变解释	数理原题/转述、Q1/Q2，以及心理匹配对打乱；跨月检查。	认知和Q1开发中心有收益，结构或另期表现未保持；不把局部信号全部叠进默认。
价格体验应通过接触传导	采购角色匹配与同月打乱；区分频率数据与强调性指令。	Qwen匹配比打乱中心仅低0.003pp，W1略差；当前价格视图沿用，但身份机制未获确认。
更强模型或更高温度是否更像人	Qwen与V3.2同输入；Flash另以0.5/0.8/1.0四遍区分人内噪声与人际差异。	V3.2共同381人月W1 2.534→1.392，支持选型；提高温度主要增加重复噪声，最终保留0.5。

表1 各行来自不同模型/月份，数值只在本行内部可比。新闻随机量按核心收益及有限代价工作采纳；原分布筛选未过的判定保留。当前实际提示为食品视图＋新闻/政策/信心/旧信念，完整CPI等宏观数表不直接投喂。 信心由Gallup资料合成匹配；E通常统一截至目标月CPI首发日纽约当地日终，而非各人的真实答卷时刻。

5 连续月份展示，两段制度分别评价

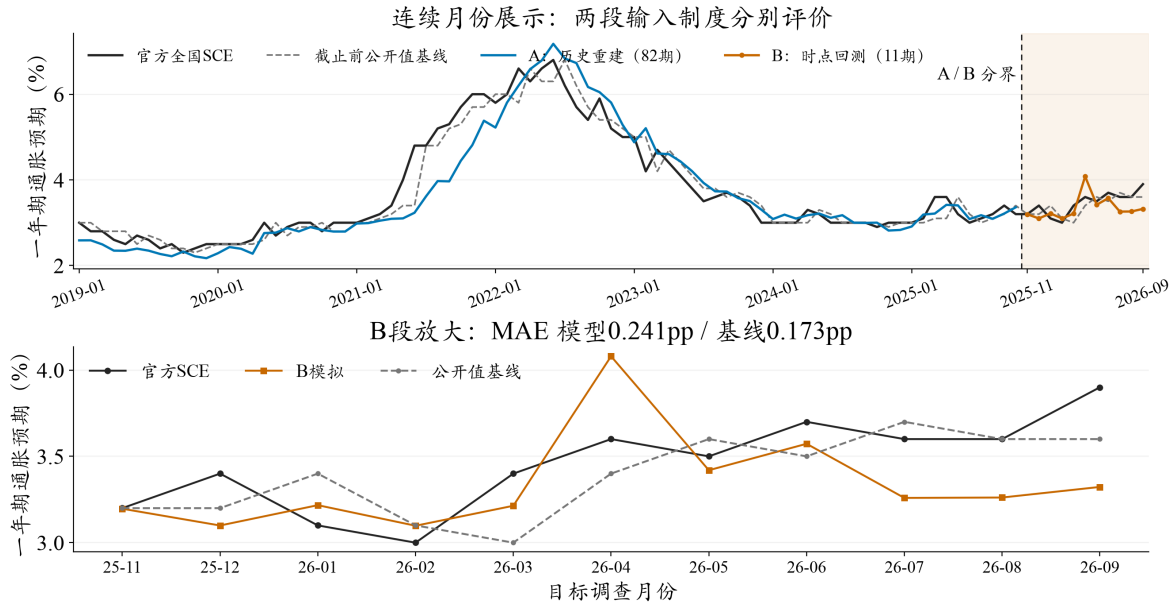


图5 上：2019-01—2026-09连续93个调查月；2025-11竖虚线区分A82与B11，阴影为B段。下：近期11期放大。A使用历史当月画像与本人既有回答，B使用滞后代理画像与合成先验；线段不跨分界连接。拼接仅作时间展示，不合报成绩，也不表示个人信念连续递推。

时期/比较	模型MAE	基线MAE	模型RMSE	基线RMSE
A：全82月	0.317	0.223	0.470	0.317
A：2021年12月	0.822	0.325	0.977	0.491
A：后34月	0.176	0.194	0.252	0.270
A：2025年1—10月	0.157	0.230	0.180	0.285
B：近期11月	0.241	0.173	0.296	0.211

表2 相对官方全国首发值的误差，单位pp；基线均取各自截止前最后公开全国值。两段输入制度不同，不能把成绩差异归因于某个单一机制。

A全期30/82月模型胜出，MAE差+0.094pp，6月区块95%区间[0.004,0.213]；2021年全年低估。后34月纯模型略优于基线，差−0.018pp、区间[−0.064,0.020]，2025年前10月胜8月，但2024年仍落后。局部改善具有时期条件，不能从有利小试推到全期。

5.1 微观资料滞后时的近期一步回测

B覆盖2025-11—2026-09，每月独立初始化，截止沿逐期CPI首发日；2025-11例外按已选11月13日。合成起点只对齐已公开历史全国Q9，不利用待预测期真值。模型5/11月胜出，平均偏差−0.114pp，4月高估与7—9月低估是主要偏离。3月区块MAE差区间[−0.045,0.190]较宽；本批是回顾性时点回测，尚非严格事前封存预测。

5.2 冻结组合与比较对象

采用无截距凸组合c=(1−λ)b＋λm，b为截止前公开值、m为模拟中心。只用2019—2022年48月拟权，MAE与MSE均选λ=0；故A后34月冻结组合MAE0.194pp，B11仍为0.173pp，分别等于基线，不能用后期重新拟权替代。A后期曾用于机制开发，因此该划分仅是权重的时间外评价。

官方全国值、完整真人波次及同支持样本仍分开报告。A固定512人相对整波Q9中位数的平均绝对偏移为0.107pp，未因偏移换种子；Q8同支持MAE为0.815pp、保留起点0.356pp。B缺近期个人真值，不报告个人误差或真人分布距离。

6 分布收缩主要发生在同类家庭内部

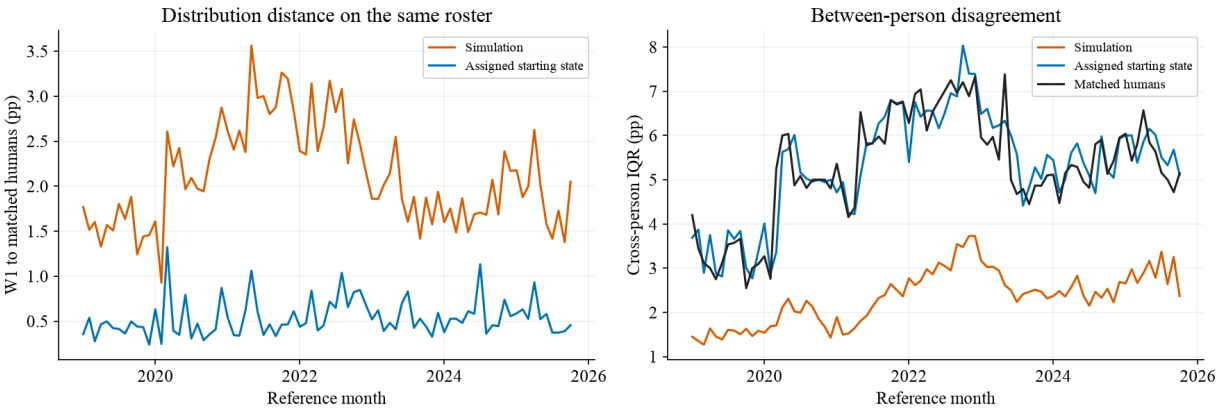


图6 同支持Q9微观结构，40,933人月。左：模型及保留起点相对真人的跨人W1；右：模型/起点/真人的跨人IQR。跨人分布基于个人密度均值，不是先平均十档概率。

总体中心的局部改善并未消除分布收缩。模型跨人W1为2.114pp，保留起点0.537pp；人际IQR为2.349pp，真人5.256pp。把中位数对齐后，W1仍为2.081pp。更重要的是，54格方差分解中约87%的净缺口发生在格内：人口比例虽然恢复了，同类人的不同判断却没有被充分重建。这正是需要把网格代表性与个体响应机制分开验证的原因。

个人密度内部IQR也偏小，模型3.941pp、真人5.651pp；零通缩概率回答占31.8%，真人54.4%。二者反映不同的填答特征，不能互相代替。仅看33,726个真实相邻回访人月，模型W1仍为1.967pp、照抄本人上期0.512pp，因此微观差距不只来自新人合成起点。

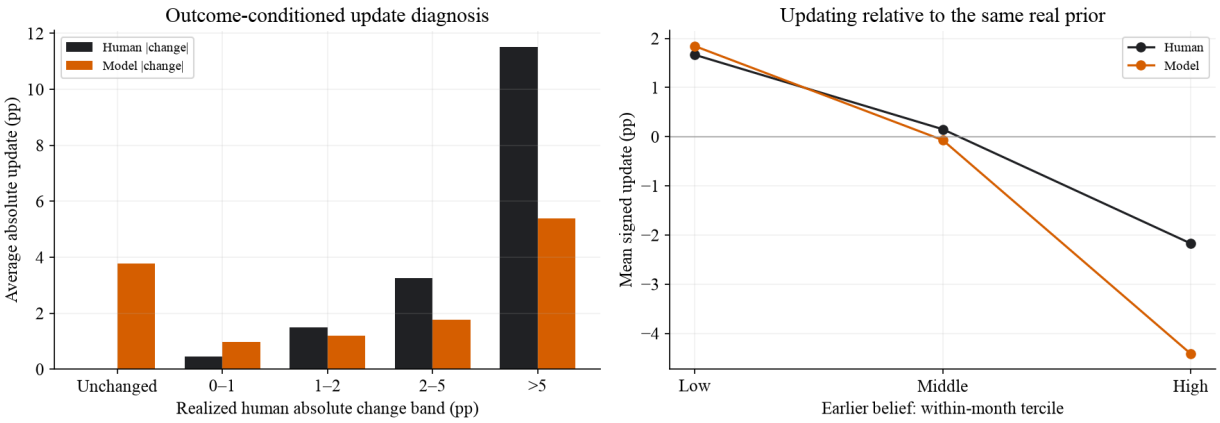


图7 真实相邻回访者的更新。左：按真人本期实际变化幅度事后分组的平均绝对更新；右：按本人旧信念月内三分组的平均有符号更新。真人/模型均减本人真实上期，左侧分组不能用于在线更新分配。

模型变化分布W1为1.244pp，小于完全不更新的2.906pp，说明它确实生成了与新环境有关的变化。但模型保持不变者只有7.35%，真人16.66%；真人不变组被平均改动3.781pp，真人变化＞5pp组的11.520pp改动却只被模拟出5.390pp。它会更新，却没有在恰当的人身上更新。

6.1 人群差异与条件信息

满足支持门槛的月份中，新人中心MAE0.816pp、回访者0.311pp；高中及以下0.665pp/大学及以上0.233pp，低数理0.649pp/高数理0.282pp，低收入0.559pp/高收入0.261pp。各组月份支持不同，以上是诊断而非人口特征的因果作用。对33,726人月的描述性加权回归，模拟单独R^2为20.42%，上期单独36.55%；控制历史、人口和月份后41.812%，再加模拟41.873%，仅增加0.061个百分点。回归不是时间外预测检验，也不提供独立人月假设下的显著性结论。

B段只能描述输出结构：每月跨人IQR平均2.325pp，合成起点5.569pp；低数理组比高数理组更分散，但没有同期微观真值，不能称分组拟合已改善。旧源供体本身也不是近期真实分布，一次生成无法分开稳定个体差异和LLM随机噪声。

7 2021年偏差的机制诊断

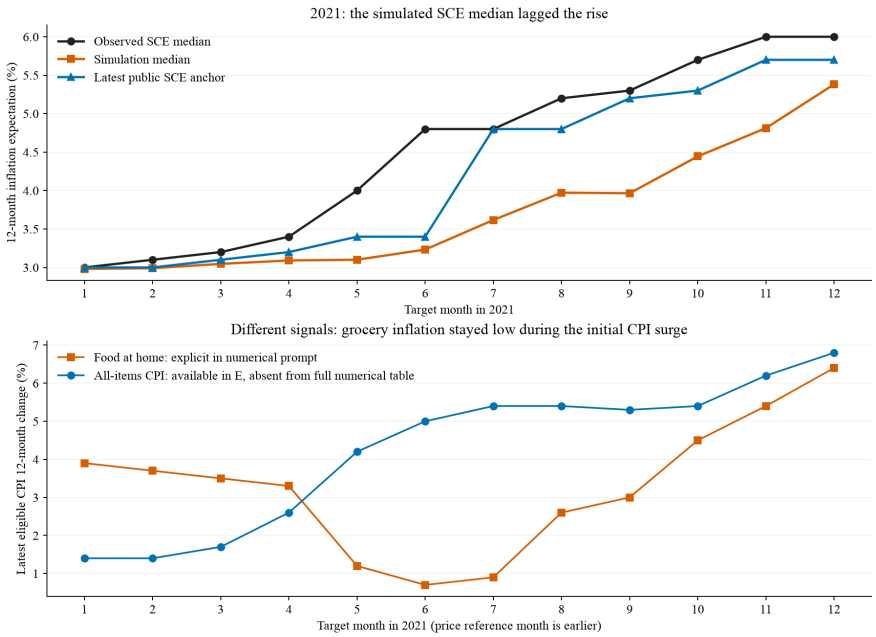


图8 2021年模拟中心与实际可见价格信号。上部是未来12个月预期；下部是截止日前公布的历史同比，二者不能混为同一目标。来源：原始请求、食品首发档案及全国评价。

为什么2021年尤其偏低？该年只占全期14.6%的月份，却贡献37.9%的绝对误差。我们先排查实现问题：6,144份实际请求与重新渲染的提示全部一致，食品原始档案、显示数值及登记日期也相符。没有发现错月或运行时丢文件，注意力由此转向“冻结设计让模型看到了什么”。

7.1 食品信号、政策叙事与个人先验可能相互作用

这里存在一个有经济含义的信号分离：5/6/7月提示中的居家食品同比为1.2%/0.7%/0.9%，同一截止日前可得总体CPI为4.2%/5.0%/5.4%，后者没有作为完整统计表直接展示。与此同时，政策摘要保留当时“暂时性”通胀判断。[7,8] 若模型把这些公共信号理解为较强的降温理由，就可能比真人更快下调已有较高预期。

回访者提供了进一步线索。2021年4,934个真实相邻人月的月度中心偏差仍为−0.715pp；6月同一400人，真人上期中位数4.000%、本期4.364%，模型却为3.262%。因此问题不只是未能预见上涨，也包括对较高旧信念的过度修正。误差分解中模型—同支持真人的−0.769pp远大于抽样项−0.064pp，两者相加的是有符号偏差，而非MAE。

7.2 2026年4月：供应风险的向上外推

相反方向的案例出现在B段4月：起点3.400%、模型4.080%，而官方从3.4%升到3.6%；Q8中位数也到4.2%，不宜仅归因于密度转换。全部512人收到伊朗战争威胁食品供应的共同新闻，352份回答理由提到战争或冲突、207份明确提到伊朗/中东/霍尔木兹，关键词可重叠。这支持供应风险驱动向上外推的解释，但生成理由不等于因果证明，也没有未暴露组。

本期模型截至4月10日，真人覆盖4月1—30日；3月风险报道仍作为共同新闻，4月初的缓和报道仅部分代理抽到。官方同时显示汽油涨价预期从3月高点下降4.3pp至5.1%。[11] 信息排序、时点与对风险持续性的判断可能共同作用；不能用月底结果反向改写4月10日输入。

7.3 从接触概率到解释幅度

2021低估与本次4月高估提示，缺口未必是统一的“过于保守”。注意到负面消息的概率，与把消息外推成一年期通胀的幅度是两个环节。Kimi正在研究媒体扩展和负面权重，当前尚无新结果；后续需同时检查低估、高估时期。新闻来源、曝光和旧信念保留仍需受控对照，不能把NYT普遍降温或负面加权必然改善拟合写为已证实机制。

8 结论与适用边界

本研究能重建部分总体走势，但A82与近期B11都未稳定胜过持续性基线，A的微观分歧和个体更新仍有明显差距。人口网格与信息匹配解决的是代表性及可接触信息，LLM如何使用这些信息还须由对照和结构检验。总体中心、分布宽度和更新对象应共同构成经验标准，而非只看一条曲线。[6]

结论限于当前输入与模型。A使用历史当期画像及个人更早回答；B改用按滞后规则推定可得的旧画像，匿名联合供体起点仅校准已公开历史全国Q9。B未设置代理人出入、Normal代答或上月模拟回灌。CE/ATUS固定年迁移、历史微观及新闻字节版本、模型知识截止均有未认证部分，不能称严格事前预测；两段每月独立初始化。

8.1 执行与复现声明

两段均为OpenRouter固定SiliconFlow FP8的DeepSeek V3.2，温度0.5、关闭思考、JSON、最多1,024输出token，每个人月一次；分配伪随机种子不等于模型采样种子。A：41,984逻辑位置、含人工补跑42,351次尝试，41,982技术完整，API报告$29.134；B：5,632逻辑位置、含20次自动补跑共5,652次，全部完整，报告$4.075。两批合计48,003次尝试/$33.209，不是全部开发成本；未知费用预留合计$1.294，不是确认扣费。A生成账本计时约223分钟，B约28分钟。

原始和修复回包分别存档，成功字段保留；A剩Q8一份/Q9两份停止补跑，极端补值对主中心MAE影响上界约0.00104pp。A的63份、B的6份概率按约定比例归一化；A有29份密度边界后备，B无密度后备。B评价漏登9月的索引错误已补官方首发资料离线恢复，未重问模型。真值只进独立评价，输入、协议、源码及结果均保留哈希；本版报告不新增模型调用或密度拟合。

> 下一步优先收束研究包：无密钥干跑、缓存重算、真实生成三种入口，补许可/数据获取说明、全项目总账和独立解压验收，再录制演示视频。Kimi新闻结果到位后独立补入。个人信念连续递推保留为扩展，不作为主线交付门槛；本稿仍为可修改的工作稿。

参考文献与资料

[1] Federal Reserve Bank of New York. SCE Frequently Asked Questions；核心问卷与数据，2026-10-24核查。 [链接]

[2] Armantier O., Topa G., van der Klaauw W., Zafar B. (2017). An Overview of the Survey of Consumer Expectations. Economic Policy Review, 23(2): 51-72. Appendix C. [链接]

[3] Huang Y., Yin Y., Lin J., et al. (2026). Uncovering Salience-Driven Dynamics in Consumer Confidence with Generative Social Simulation. arXiv:2606.30395. 同时参照SocioVerse2框架与赛事P/E/B要求。 [链接]

[4] Mankiw N. G., Reis R. (2002). Sticky Information versus Sticky Prices. Quarterly Journal of Economics, 117(4): 1295-1328. 信息更新成本作为理论动机，未直接校准本文家庭更新率。 [链接]

[5] D'Acunto F., Malmendier U., Ospina J., Weber M. (2021). Exposure to Grocery Prices and Inflation Expectations. Journal of Political Economy, 129(5): 1615-1639. [链接]

[6] Bisbee J., Clinton J. D., Dorff C., Kenkel B., Larson J. M. (2024). Synthetic Replacements for Human Survey Data? The Perils of Large Language Models. Political Analysis, 32(4): 401-416. [链接]

[7] U.S. Bureau of Labor Statistics. CPI News Release, 2021-06-10（May 2021参考期）；其余逐月首发稿随研究档案保存。 [链接]

[8] Federal Reserve. FOMC Statement, 2021-04-28；本项目原始请求及政策摘要保留各月版本。 [链接]

[9] Malmendier U., Nagel S. (2016). Learning from Inflation Experiences. Quarterly Journal of Economics, 131(1): 53-87. [链接]

[10] Pfajfar D., Winkler F. (2024). Households' Preferences Over Inflation and Monetary Policy Tradeoffs. June working paper, §4.1/Table 1. [链接]

[11] Federal Reserve Bank of New York. April 2026 SCE release, May 7, 2026；仅作为评价后诊断，不进入4月10日输入。 [链接]