居民通胀预期的智能体重建

机制依据、设计选择与跨时期评估

水上挽月 · SocioVerse Challenge 2026 · 赛道A：历史重建与未来预测

版本 v0.5 · 2026-10-26

居民通胀预期同时受既有信念、生活价格与公共信息影响。本文用纽约联储SCE检验生成式社会模拟能否重建全国中心与微观差异。新版A T0按受访者完成日前一日筛选信息，2019年1月至2025年10月全国Q9中心MAE为0.298个百分点，较旧A的0.317略低，但仍高于公开历史基线0.223。2021全年MAE由0.822降至0.577，仍高于0.325基线。W1、跨人IQR和Q8个体误差显示收益并不全面。B11仍沿用v0.4旧结果，MAE为0.241、基线0.173，未刷新。A是回顾性重建，不称严格事前预测；两段不合并评分。

关键词：通胀预期；生成式社会模拟；异质家庭；信息接触；概率问卷

1 研究问题与理论框架

家庭怎样看待未来物价，会影响消费、储蓄和工资判断，也是政策沟通的重要问题。只拟合一条全国曲线，却可能掩盖微观机制的错误：高预期与低预期家庭的偏差可以互相抵消，缺乏个人差异的模型也可能碰巧得到正确中位数。我们把人群P（家庭背景与既有状态）、环境E（可见信息）和行为B（问卷回答）分开，因此同时研究总体中心、家庭之间的分歧，以及同一家庭如何修订判断。SCE答卷分布在当月不同周，共同月中截止可能造成信息时点错配；新版T0按实际完成日构造个人可得信息窗口。

1.1 SCE调查的研究价值

SCE由纽约联储开展，自2013年起按月调查美国户主。官网FAQ目前表述约1,200人，采用全国代表性的线上轮换面板；受访者最多连续参与12个月，答卷分布在当月各周。全国摘要按月发布，核心微观资料约滞后9个月公开。[1,2] 它既能追踪个人更新，又同时询问点判断和概率分布，适合检验“平均看起来合理，个人行为却不相似”的问题。本文预测的是居民对未来12个月通胀的看法，并非把实际CPI当成调查答案。

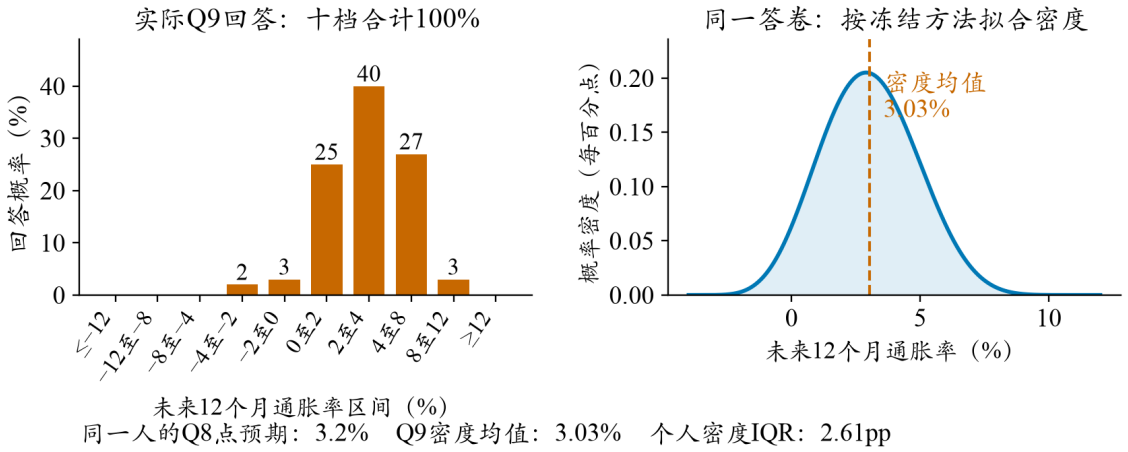
1.2 从理论依据到机制假设

理论线索	对预期形成的启发	本项目可检验的设计
信息更新有成本[4]	公开信息不等于人人接触、理解和吸收；旧信念可能持续。	保留真实历史，允许保持或更新；分别检验新闻数量与主题。
生活价格具有显著性[5]	购买中反复接触的涨价可能比支出占比更能影响判断。	从家庭结构匹配采购角色，再改变可见价格，设置打乱对照。
经历与认知存在差异[9]	经历的时间长度、数理理解和资源约束可能塑造不同响应。	先用真人数据筛选人口维度，再检验认知/财务信息能否改变模型。

这些文献提供的是传导方向，而不是可直接套用的个人更新系数。我们的研究策略是先把每条理论路径变成明确的输入差异，再用对照实验判断模型是否真的使用了这些信息。ConsumerSim提供了人口、环境、回答和惯性校准分层比较的参照；本项目进一步利用SCE微观答卷，检查聚合拟合之外的行为结构。[3]

2 SCE问卷与指标构建

两道题都面向未来12个月，却记录不同层面的判断。Q8询问预计通胀或通缩的幅度，是一个点预期；Q9要求为十个可能区间分配概率，表达未来涨幅的不确定性。图1展示2025年6月一位实际受访者的答卷：Q8为3.2%，Q9则把40%的概率分配给2—4%，27%给4—8%，25%给0—2%，其余概率落在其他区间。两题来自同一人，点判断和密度均值不必完全一致。



来源：SCE 2025年6月公开微观答卷；单个受访者示例，不代表当月总体。

图1 真实SCE答卷及其密度转换。来源为2025年6月公开微观资料，左侧为原始十档概率，右侧按本项目冻结算法拟合，密度均值3.03%、个人密度IQR为2.61pp。仅展示一位受访者，不代表当月总体；未展示身份或人口特征。

2.1 从十档概率到个人密度，再到人群中位数

每档概率须在0—100%之间，合计100%；负的通胀预期合法，负的概率不合法。按照SCE方法的研究复现，单个闭区间用均匀分布，两个相邻正概率区间用三角分布，至少三个正概率档拟合广义Beta密度。Beta参数通过带约束最小二乘，使有效档界的累计概率尽量贴近回答。随后取每人密度的均值μ，而不是先把所有人的十档概率平均。最后将这些个人均值按人口权重排序，累计权重首次达到50%的位置，就是本项目的群体中位数。

这样就区分了两种“宽度”：一位受访者的密度IQR反映他对未来有多不确定；不同受访者的密度均值IQR反映人群有多大分歧。两者可以朝不同方向变化。官方概念同样先取个人密度均值，但本项目冻结的近似拟合和经验CDF左逆分位数并不等于官方全部优化及插值细节，因此另列官方全国值与同支持微观比较。[1,2]

评测问题	采用指标	怎样理解
总体中心准不准	MAE、RMSE、bias，单位为百分点（pp）。	MAE看平均绝对偏差；RMSE更重视大偏差；bias区分偏高或偏低。
结构是否相似	跨人W1、跨人IQR、个人密度IQR。	W1是两条分位数曲线距离的面积；IQR=P75−P25，应与真人对照，不是越大越好。
是否在正确的人身上更新	相对本人真实上期的变化W1、保持率、大变化率及分组误差。	让模型产生更多变化，并不保证它能识别谁会改变、谁会保持。

3 人口分层的统计依据

若只按少数粗特征抽样，可能遗漏重要群体；若把所有人口字段交叉，小格又会缺乏支持。我们因此把“对回答有多少独立信息”和“能否获得可靠支持”分开判断。使用98,382个历史人月构成的框架，从学历、数理、收入、年龄、就业、性别、住房和地区八项中比较126套三/四维候选；监督分析在八项已知且答卷有效的95,375人月共同支持上进行。

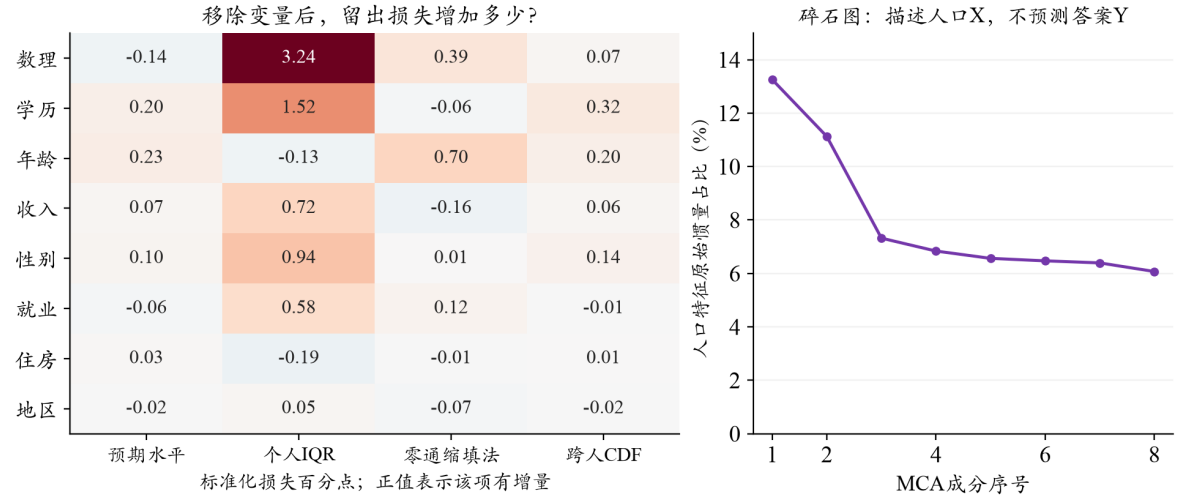


图2 既有统计证据。左：2019—2022年按受访者四折留出，移除一整项特征并重新拟合后的损失变化（标准化损失百分点，非通胀pp）。右：分类变量MCA碎石图，只描述人口X的共变，不能当作问卷Y的解释率。

左图显示，数理与学历对个人不确定性较有增量，年龄更多关联预期水平和零通缩填法，各变量的用途并不相同。我们同时检查了冗余：学历—数理的加权Cramer V约0.317，整块调整GVIF仅1.007—1.186，没有证据需要因严重共线性机械删除其中一项。MCA帮助描述结构，最终取舍仍以留出表现和抽样支持为依据。

3.1 维度选择与有限样本下的代表性

四领域等权评分涵盖个人均值、密度IQR、零通缩填法和均值CDF；它衡量月内异质性，不是全国MAE。相对无人群差异参照，旧“学历×在职”六格的平均标准化损失改善为2.160%，学历×数理×年龄×收入为4.917%；后两段时间检查为5.413%和5.471%。原较严支持约定偏向更省样本的“学历×数理×性别”12格，但年龄和收入也提供资源与经历维度。允许小格过采样后，我们据此选择四维54格，而不是把12格或碎石图的某个拐点视为唯一答案。

实际分类为学历3档、数理高/低、年龄＜40/40—60/＞60、年家庭收入＜5万/5—10万/＞10万美元；未知另池。每月抽512人，非空格尽量保底8人，小格全取，余额按人口质量分配。固定种子20261023按人无放回排序，不读取本期预期；设计权重w/π再在格内校准，使过采样的小格汇总时回到其真实人口比例。82个月均可分配，格质量误差＜1e-12，但512人方案只有约60%的质量落在格内ESS≥10的格，不能把覆盖当作精度保证。 就业、住房与地区仍进入画像，不因未列为网格坐标而删除；调查权重和原始身份不发给模型。

3.2 分层画像与个人历史的结合

同类家庭内部仍可能有不同习惯与经历。因此，网格只决定抽样和分组，模型仍读取本人更早的Q8/Q9及历史摘要。没有历史者从最近1—3个月同类匿名新/老受访者池取得联合起点，并保留合成标签；本期答案不参与匹配。新人同样由LLM作答，不用Normal复制来填补身份信息。

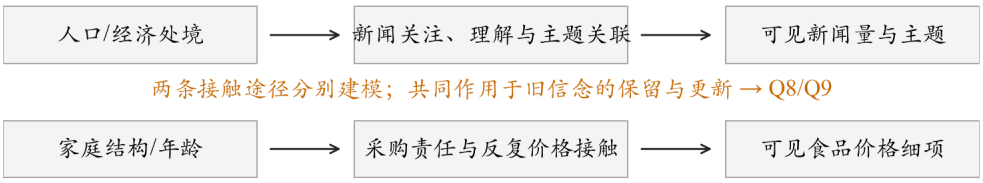
3.3 样本加权与近期人口来源

A、B两段都由每月512人直接调用LLM，没有Core＋Normal贝叶斯扩展，也不把其余人复制成新答卷。代表性由抽样权重承担：在格h内，先按原调查权重除以入选概率π，再乘校准系数，使各格权重质量恢复源人口比例；经验CDF按权重而非人数累计，达到50%处取中位数。权重可以是非整数，扩成约1,300个标签并不会凭空增加信息。

A以历史当月人口为源，缺历史者才匹配近期联合供体。B受微观披露滞后约束，按“源调查月末加九个日历月且早于截止”的推定规则逐月取源，2025-11用2025-01，推进至2026-08/09用2025-10；精确历史字节版本尚未认证。B权重代表相应旧源，而非已知近期真实人口；就业、收入随源记录，不额外宏观修正。合成Q8/Q9保持供体联合答卷，分配后仅将历史Q9中心校准到当时已公开全国值±0.05pp。此步骤是初始化，不是扩样；Q8不强加Q9锚。

4 信息接触机制与实验设计

有限注意力意味着“公开可得”与“本人接触”之间还有选择过程。SCE专项研究发现，学历、收入及年龄与宏观关注有关，但关系依主题而变，通胀关注回归的伪R^2仅0.027。[10] 这不能换算成个人阅读篇数，却提醒我们保留大量组内差异：高学历不等于一定看很多新闻，经常采购也不等于经常读财经报道。



文献提供传导动机；CE/ATUS与关注资料仅提供代理分配，不等于本人真实接触记录。

图3 理论路径与操作化。新闻与购物价格是两种信息接触；本人旧信念另行保留。箭头表示待检验的机制路径，不是本文已识别的因果系数。

既有新闻量比较使用3/8/20篇作为广度实验，并非文献估计的真实阅读量。新版A T0改用4/8/16/32篇、CPI相关度1.5，并按个人问卷完成日筛选可见新闻、食品统计、政策与信心；新旧结果同时改变了篇数、抽样/路由和截止时点，不能据此分离单一因素的因果作用。

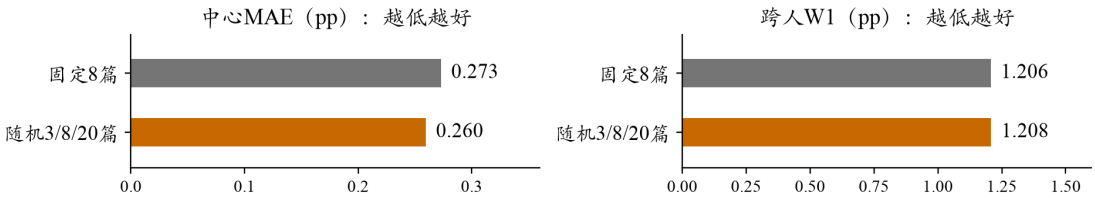


图4 V3.2八期新闻量对照的直接两组共同支持，1,116人月、两遍生成。随机量中心略改善，W1几乎不变；3/8/20的篇数与比例是可比成本下的实验设定，并非文献估计的真实阅读量。

理论依据	对照设计	证据与取舍
旧信念具有持续性	明确个人起点与时序；另比较固定半程更新指导。	Flash先验表达使W1 2.617→2.329，中心未同步改善；保留状态，不规定固定更新幅度。
认知与财务处境可能改变解释	数理原题/转述、Q1/Q2，以及心理匹配对打乱；跨月检查。	认知和Q1开发中心有收益，结构或另期表现未保持；不把局部信号全部叠进默认。
价格体验应通过接触传导	采购角色匹配与同月打乱；区分频率数据与强调性指令。	Qwen匹配比打乱中心仅低0.003pp，W1略差；当前价格视图沿用，但身份机制未获确认。
更强模型或更高温度是否更像人	Qwen与V3.2同输入；Flash另以0.5/0.8/1.0四遍区分人内噪声与人际差异。	V3.2共同381人月W1 2.534→1.392，支持选型；提高温度主要增加重复噪声，最终保留0.5。

表1 各行来自不同模型/月份，数值只在本行内部可比。新闻随机量按核心收益及有限代价工作采纳，原分布筛选未过的判定保留。旧配置E通常统一截至目标月CPI首发日当地日终；新版T0改为实际完成日前一日纽约时间23:59:59。没有答题小时，故该日期是保守窗口代理，并不记录真实阅读或注意。

5 A T0全国中心：略优于旧A，仍落后公开基线

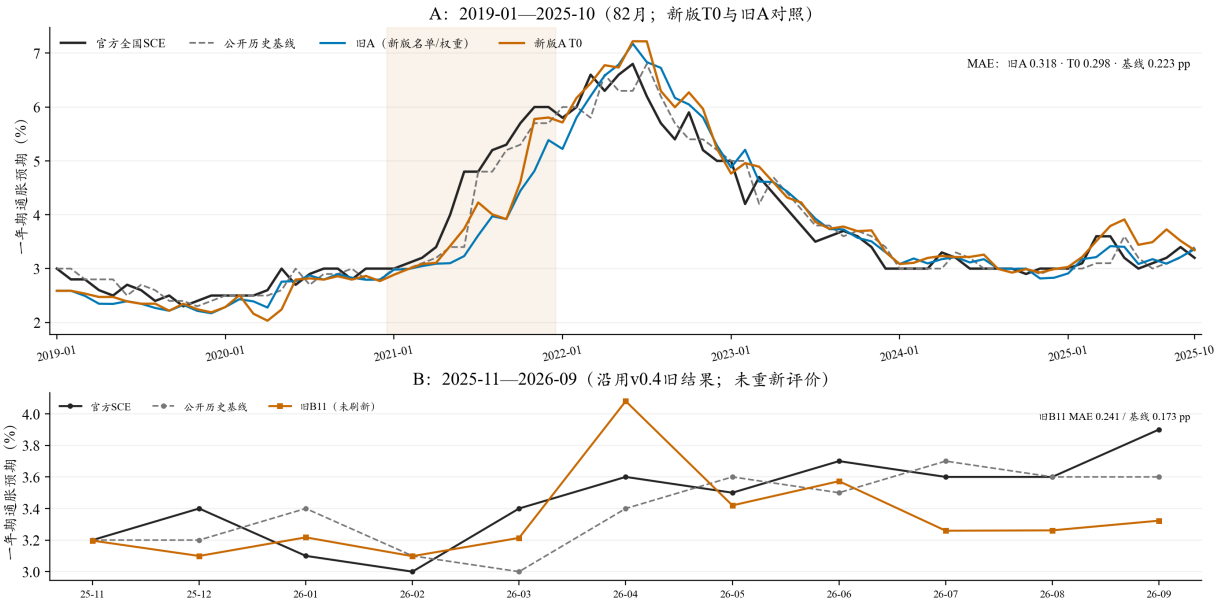


图5 上：82个月旧A（按新版T0名单/权重重算，MAE 0.318）、新版T0、官方SCE与公开历史基线；下：B11沿用v0.4旧结果，未刷新。A、B分面展示，不跨段连线或合报成绩。A为个人日期窗口与54格历史重建；B使用滞后代理人口和旧供体先验，配置不同。表2旧A的0.317为原全名单MAE。

比较范围	旧A	新版T0	公开历史基线/结果
全82月Q9中心MAE（pp）	0.317	0.298	0.223
2021全年Q9中心MAE（pp）	0.822	0.577	0.325
后34月纯模型MAE（pp）	0.176	0.215	0.194
早48月MAE拟权λ；后34月MAE	0；0.194	0；0.194	=基线
早48月MSE拟权λ；后34月MAE	0；0.194	0.134；0.184	0.194；差区间跨0

全期MAE差（新版T0−旧A）为−0.0187pp，6月块95%区间[−0.0941, 0.0493]；公开历史基线沿用旧共同月中锚，不是按每位受访者日期对齐的严格预测基线。48/34分段曾进入探索性开发，不是未触碰盲测。

新版T0相较旧A降低全期MAE约5.9%，但仅39/82月误差更小；区间跨零，不能称稳健胜出。2020年MAE由0.150升至0.231，2025年1—10月由0.157升至0.276。全期公开基线0.223仍低于T0。2021虽改善，仍需单独看误差来源。

5.1 B11旧结果保留，不纳入新版A评价

B11覆盖2025-11—2026-09，旧v0.4模型/基线MAE为0.241/0.173pp；本版未刷新。B与A的画像、起点和可得性规则不同，A+B不计算综合MAE，也不称严格事前预测。

5.2 48/34组合的收益边界

以2019—2022早48月拟权，MAE选择λ=0，后34月组合与基线同为0.194pp。MSE选择λ=0.134，后34月组合MAE为0.184pp，较基线少0.010pp，但95%区间[−0.0214, 0.0008]跨零；此组合仍不优于旧A纯模型0.176。对全82月重新拟权得到MAE 0.222仅属样本内描述，不能作验证成绩。

6 全国中心的小幅变化没有消除微观收缩

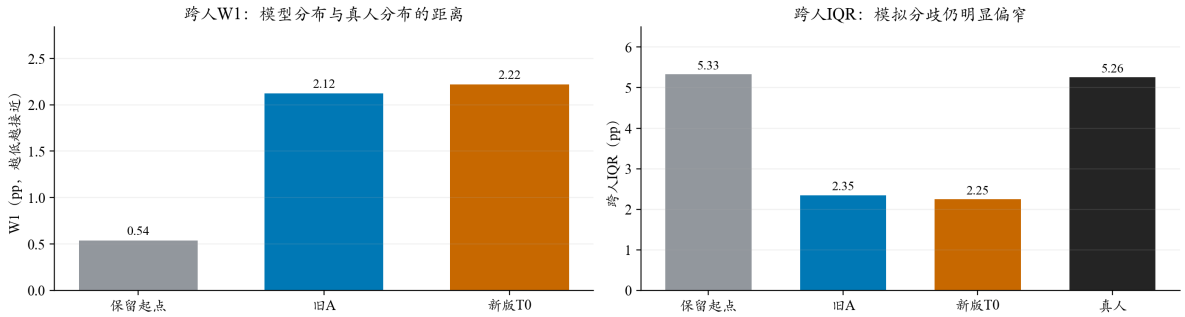


图6 同支持Q9微观比较。W1衡量模型分布与真人分布距离；跨人IQR展示真人间判断宽度。样本为41,042个Q9人月。

同支持Q9中心MAE由旧A的0.314降至T0的0.310pp，但W1由2.121升至2.219pp；跨人IQR从2.348降至2.248pp，仍远低于真人5.261pp。个人密度IQR均值为3.958pp，真人为5.650pp。中心接近不代表分布或人际差异被重建。

在33,715个真实相邻上期回答的人月中，T0 Q9中心MAE为0.309pp、W1为2.064；照抄本人上期分别为0.211和0.512。模型仍未超过真正的个体持续性基线。

6.1 Q8的中心与个体误差方向不同

同支持Q8中心MAE由0.818降至0.722pp，但个体Q8 MAE由8.173升至8.215pp；保留起点的Q8中心MAE为0.356pp。因此，T0对同支持样本的Q8群体中心有改善，对个体回答并未全面改善，不能把Q9中心收益概括为问卷整体精度提升。

W1与IQR衡量不同问题：前者看分布离真人有多远，后者看人际分歧有多宽；两者都不应被“更多更新”替代。T0仍主要重建总体走势，尚未充分恢复同类家庭内部的判断差异。

7 2021全年：九个月改善，仍落后基线

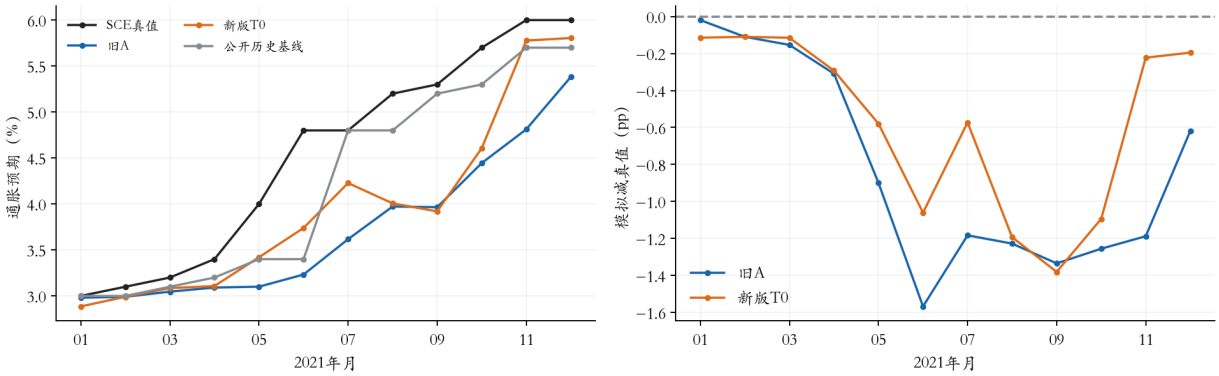


图7 2021逐月SCE全国值、旧A、新版T0与公开历史基线；右图为相对真实值误差。新版T0全年仍呈负偏差。

2021年Q9中心MAE从旧A的0.822降至T0的0.577pp，12个月中9个月改善；但仍高于公开历史基线0.325pp，年度bias为−0.577pp。该年占全期误差的比例从旧A约37.9%降至T0约28.3%，仍是重要偏差来源。

7.1 为什么改善不等于识别了原因

T0针对共同月中截止的一个时间错配：SCE答卷分散在当月不同周，按完成日前一日筛选可避免把之后发布的信息默认给较早作答者。旧诊断还提示食品价格与总体CPI信号、政策中的“暂时性”判断可能交互影响预期。[7,8] 但T0同时改变新闻篇数、抽样/路由与个人截止，不能把2021改善归因于其中某一项，也未证明具体信号机制。

7.2 相反方向的旧B11案例

旧B11的2026年4月出现向上外推：模型中心4.08%、官方3.6%、起点3.4%；512人都收到食品供应风险新闻，生成理由中352份提及战争或冲突、207份提及伊朗/中东/霍尔木兹。该案例保留自v0.4且未更新；理由共现不是因果证据，也无未暴露对照。[11]

2021低估与2026年4月高估方向相反，说明问题不只是统一的“更保守”。注意到信息与将其外推成一年期通胀是两个环节；本稿把这类解释作为待检验机制，不写成已证实结论。

新版T0相较旧A在全期与2021全国中心有所改善，但仍未胜过公开持续性基线；Q9微观W1/IQR、真实上期基线和Q8个体误差也未全面改善。A使用历史人口与本人更早回答、按完成日前一日筛选环境，是回顾性重建；B11沿用v0.4滞后代理人口与供体先验，分开报告，不拼成严格事前成绩。T0同步改变信息时点、新闻篇数和抽样/路由，差异不能归因于单一因素。[6]

CE/ATUS固定年迁移、历史微观与新闻的完整字节版本、模型知识截止均未认证；个人日期窗口不等于真实阅读记录。即使时间顺序上留出后34月，相关时期也已进入此前机制开发，不能称严格预测或独立盲测。

B未设置代理人出入、Normal代答或上月模拟回灌；A与B均按各自批次协议逐月独立初始化。两段输入制度与评价支持不同，不将拼接曲线解释为个人状态递推。

8.1 执行与复现声明

新版A覆盖41,970个合格人月；182个经过核验的历史回答复用，41,788次新主请求，另有241次技术补跑，共42,029次新物理尝试。供应商报告费用$33.060，未知费用预留$0.904另列，未重复计入历史复用费用。Q8输出41,970份；Q9有41,969份可用，1份保留起点，13份密度拟合按冻结后备规则处理。

评价使用冻结Q9计分器离线处理9,262个新回答向量，未发起新API；运行器自动评价未启动后另行调用独立离线评价入口。报告渲染新增API和评分拟合均为0。输入、回包、评价及来源哈希保留；新旧A改动不止个人时间窗口，所有对照均属探索性证据。B11成本和结果沿用v0.4。

> 研究包已有离线与隔离复算验收；完整微观数据访问与分发、模型时间边界及最终赛事材料仍需按提交清单核验。后续报告应保留旧B11标签，新增结果须另版登记；本稿为可修改工作稿，不代表严格预测或最终提交认证。

参考文献与资料

[1] Federal Reserve Bank of New York. SCE Frequently Asked Questions；核心问卷与数据，2026-10-24核查。 [链接]

[2] Armantier O., Topa G., van der Klaauw W., Zafar B. (2017). An Overview of the Survey of Consumer Expectations. Economic Policy Review, 23(2): 51-72. Appendix C. [链接]

[3] Huang Y., Yin Y., Lin J., et al. (2026). Uncovering Salience-Driven Dynamics in Consumer Confidence with Generative Social Simulation. arXiv:2606.30395. 同时参照SocioVerse2框架与赛事P/E/B要求。 [链接]

[4] Mankiw N. G., Reis R. (2002). Sticky Information versus Sticky Prices. Quarterly Journal of Economics, 117(4): 1295-1328. 信息更新成本作为理论动机，未直接校准本文家庭更新率。 [链接]

[5] D'Acunto F., Malmendier U., Ospina J., Weber M. (2021). Exposure to Grocery Prices and Inflation Expectations. Journal of Political Economy, 129(5): 1615-1639. [链接]

[6] Bisbee J., Clinton J. D., Dorff C., Kenkel B., Larson J. M. (2024). Synthetic Replacements for Human Survey Data? The Perils of Large Language Models. Political Analysis, 32(4): 401-416. [链接]

[7] U.S. Bureau of Labor Statistics. CPI News Release, 2021-06-10（May 2021参考期）；其余逐月首发稿随研究档案保存。 [链接]

[8] Federal Reserve. FOMC Statement, 2021-04-28；本项目原始请求及政策摘要保留各月版本。 [链接]

[9] Malmendier U., Nagel S. (2016). Learning from Inflation Experiences. Quarterly Journal of Economics, 131(1): 53-87. [链接]

[10] Pfajfar D., Winkler F. (2024). Households' Preferences Over Inflation and Monetary Policy Tradeoffs. June working paper, §4.1/Table 1. [链接]

[11] Federal Reserve Bank of New York. April 2026 SCE release, May 7, 2026；仅作为评价后诊断，不进入4月10日输入。 [链接]