美国居民通胀预期的Agent模拟

基于SCE的历史重建与方法验证

给定家庭特征、信息环境与既有信念，
Agent能否生成接近真实调查的预期及其分布？

阶段判断

调查模拟流程已贯通。
总体拟合与个人差异仍未达到稳定有效的标准。

水上挽月 · 复旦大学 · 2026年10月15日

SCE：纽约联储的消费者预期调查

Survey of Consumer Expectations。我们研究其中的“一年期通胀预期”，即居民判断未来12个月物价会变化多少。

调查制度	具体情况
调查机构	美国纽约联邦储备银行（纽约联储）
调查频率与起点	2013年6月启动，每月在线调查，月内分周收集
调查对象与规模	美国家庭财务负责人，设计规模约1,200人 / 月
同一人能参加多久	每人最多跟踪12个月，每月有一部分人退出与加入
月度指标何时公开	通常在调查次月公布，具体日期按官方日历
逐人微观数据何时公开	核心调查滞后9个月，晚于月度汇总指标

选择SCE的原因

通胀预期影响消费、工资判断和政策传导，具有直接的经济学意义。

原问卷、人口画像、逐人概率回答与跨月记录可用于构造和检验Agent。

既能对照总体指标，也能检验家庭分歧和信念更新。

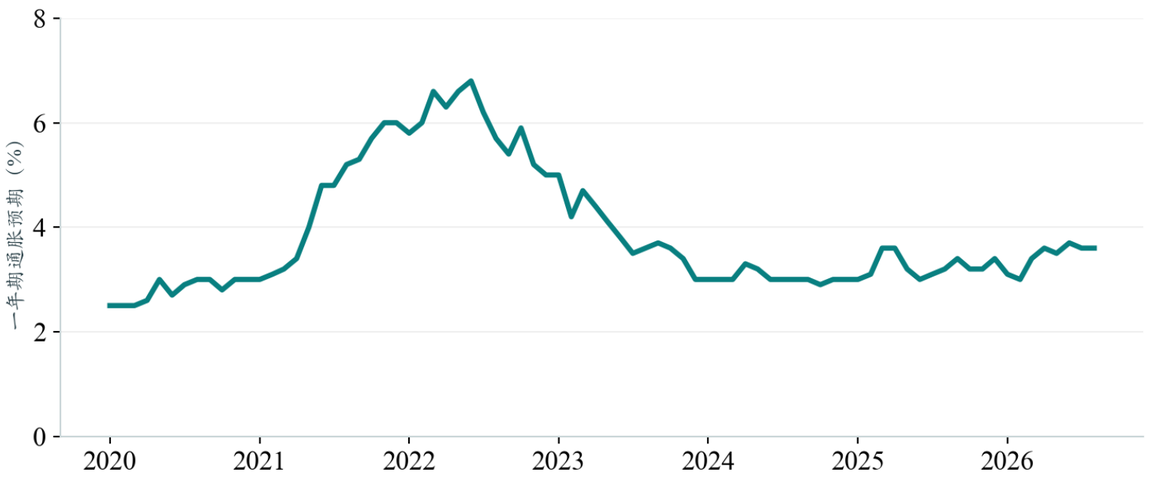
月度指标更新较快，个人记录公布较慢。这决定了历史重建与未来预测需要不同的人口输入。

来源：纽约联储SCE FAQ与官方发布档案，2026-10-15核查。约1,200人为当前FAQ设计规模，实际月样本不同。[2]

研究目标：总体水平与家庭预期分布

用同一套模拟，同时检验群体中位数、家庭之间的分歧，以及同一家庭的逐月变化。

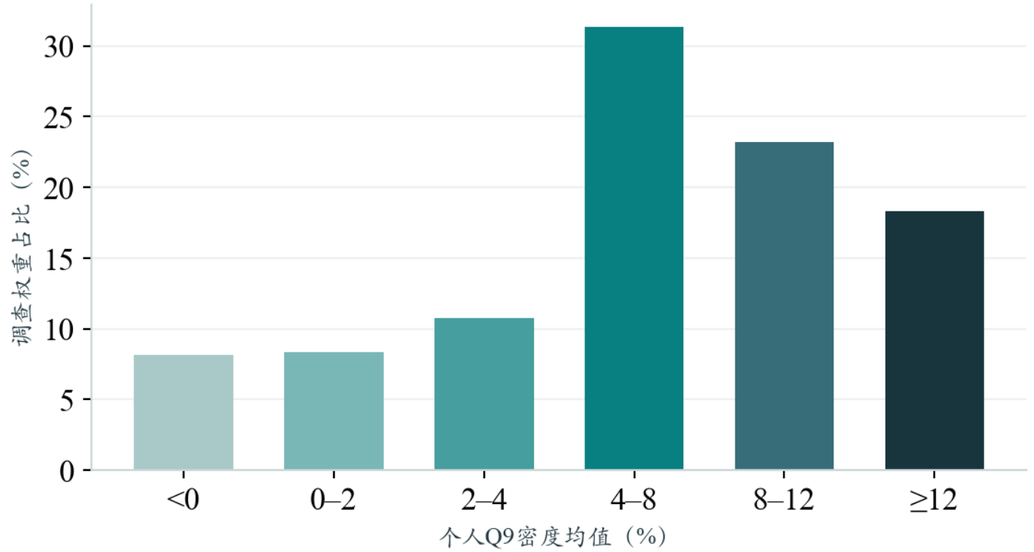
预期随经济环境变化



官方全国指标：2020-01至2026-08

已归档资料版，不代表官网当前最新一期。

同一月份，家庭判断也不同



真人2022-06，有效1,202条，官方派生值、调查权重。

包含全部尾部；与后文实验样本及计分口径不同。

总体指标需要接近真实调查。Agent方法的额外价值，在于能否同时还原家庭差异及其变化。

来源：NY Fed SCE公开月度指标（10/07归档）；SCE微观2022-06；官方FAQ。[1–2]

历史重建与未来预测的信息使用范围

关键区别是研究者能否利用后来公开的资料还原历史。当前实验以历史重建为主。

比较维度	A 历史重建	B 未来预测
研究目标	事后重建某月家庭回答与分布	在结果公布前预测下一调查月
人口与已有信念	可用后来公开的该月真实画像、本人过去回答	只用截止前已有的旧人口或合成人口，信念自行递推
经济与新闻资料	可事后整理历史背景。当前实验仍按调查窗口截断新闻与价格	只可使用预先确定的预测截止日前已公开资料
真实调查答案	本项目未将当期答案作为输入，只在生成后检验	预测时不可获得，公布后再进行评价

例：事后重建2022年6月可使用6月真实画像，而在5月末预测6月时，这些微观记录尚未公开。

两条路线中的家庭都可以只接触当时信息。A允许研究者事后还原人口，B要求整套方案在截止日可执行。

项目路线A/B设计与八期协议；赛道A允许历史重建与未来预测。[1] 本页只说明设计，不改运行配置。

P/E/B框架：居民、信息与作答过程

P刻画居民的处境与原有信念，E描述其接触的信息，B是模型据此形成并表达预期的过程。

Population 居民是谁

年龄、收入、教育、就业
住房、数理能力
本人过去的通胀预期

来源：SCE微观与历史回答

+

Environment 接触什么

已公布的价格与变化趋势
经济事件、新闻与政策
按家庭处境分配部分信息

来源：官方统计、价格与纽约时报

→

Behavior 如何作答

理解信息，保留或修正旧信念
给出Q8点预测与Q9概率
再由计分程序形成统计量

实现：语言模型（LLM）作答

需要检验的传导机制

价格体验
购买与接触频率如何影响价格关注。

信念更新
新信息如何改变原有判断。

认知与表达
数字理解如何影响概率分配。

合成补充参考CE消费调查与Gallup信心调查。分配给个人仍含假设，其行为效果需要单独验证。

参考SocioVerse官方CCI/PMI案例和ConsumerSim。经济学机制依据见[3–6]，具体实现由实验检验。

项目各环节的完成情况

按SocioVerse研究流程梳理已完成工作，以及尚需验证的问题。

研究环节	已实现 / 已核验	距离目标的缺口
Literature review	价格体验、信念更新、概率认知已有综述	理论尚未全部转成有效机制
Study	A/B边界、对照和时间范围已声明	B递推与全国代表性待验
Population	实测画像、过去回答、合成属性已接入	人口更新与新加入者仍需补齐
Environment	价格、新闻、政策与个人视图已构建	接触强度和理解机制待验证
Dataset	106个月微观资料；来源及发布时间台账	各来源覆盖不同，不能视作全部同步
Simulation	本地真实LLM已多轮运行	尚未稳定优于简单基线
Trajectory	原始消息、回答、失败、用量可追溯	完整提交包独立验收待完成
Analysis	同样本中心、分布、更新及基线评价	独立新时期与公平信息对照待扩大
Reports	开题已提交；本次汇报与证据索引	最终论文、复现包、演示尚未成稿

数据、模拟、计分和评价已贯通，当前工作集中于改善拟合并验证居民行为机制。

项目清单与运行收据，截至2026-10-15。

数据来源、用途与覆盖范围

输入资料用于构造居民与环境。当期真实通胀答案在模型生成后用于评价。

数据来源	在项目中的用途	覆盖与边界
SCE微观＋原问卷	人口、本人历史、真实回答与原始题意	2017-01至2025-10；106个月、130,216人月
SCE官方月度指标	全国时间序列与外部统计口径核对	归档指标示例延伸至2026-08；不同于微观覆盖
美国劳工统计局（BLS）	首发新闻稿中的CPI、就业及其他宏观信号	按实际发布日期入窗；首发值与修订值分开
能源信息署（EIA）等	较及时的能源价格与家庭近期价格线索	仅在已取得历史时间证据的窗口使用
纽约时报（NYT）档案	公开事件背景、政策与家庭相关消息	关键词粗筛后由LLM分类，再抽取个人新闻
消费者支出调查（CE）	支出表与Diary日记数据，用于合成消费结构和购买日数	供体家庭非SCE本人，跨年覆盖与发布时间有缺口

价格与就业优先使用历史首发稿，保留实际公开日期，避免将后来修订值误当作当时已知值。

已归档来源：NY Fed、BLS、EIA、NYT Archive API、CE，数据清单及限制见附录C。

居民画像与原有信念的构造

实测信息、本人历史与合成补充分别记录。右侧仅为虚构示例。

实测画像

年龄组、学历、收入档、就业、住房、地区、数理能力等；需按本人历史维护更新。

本人过去信念

上期Q8、十档Q9，以及更早回答摘要。当前A条件重建可用，不等于B递推已完成。

外部迁移的合成属性

CE消费结构、购买日数和部分信心标签：有现实参考，但分配给个人仍含假设。

一个虚构家庭的输入结构

40–59岁 · 租房 · 中等收入

在职 · 本科 · 数理能力标签

上期认为未来一年物价会上涨

保留本人当时的概率分配

合成篮子：食品 / 家居 / 个人护理等

新加入者没有本人上期回答，需另设初始化；不能用当期真实预期补齐。

后续将检验人口特征是否真正改变信息接触、理解与更新，而不只检查提示词是否列出了该特征。

SCE微观与问卷、CE供体匹配、既有信念状态规范。Core/Normal的说明见附录E。

公共信息与家庭信息接触

保存完整事实库以便核查，再选择每个家庭实际接收的内容。信息分配方式仍需检验。

公共事实库

首发价格与就业数据
过去趋势，注明同比 / 环比
较及时的汽油等价格
事件、政策与新闻摘要
记录观测期、公开日、版本

→

信息分配

共同新闻背景
个人抽取的新闻
随机性与家庭相关性结合
50%随机 + 50%相关加权
尚待跨时期验证

→

家庭实际接收的提示

日常价格与经济背景
部分不同的新闻组合
家庭特征与旧信念
仍可能过于像一份统计简报，
而非居民的日常信息环境。

已发现：单纯增加信息、消费类别或频率标签，尚未稳定改善拟合。

重点检验家庭接触何种信息、如何理解涨价及其持续性，再决定是否增加新的指标和新闻。

既有新闻分类与信息分配实验。50/50为项目设定，尚无代表性参数估计。

模拟流程与运行记录

模型直接填写本期Q8与Q9，并可参考本人上期信念。各阶段保留可核查的输入与输出。

01 输入
P / E / 历史信念
→
02 行为
真实LLM回答
→
03 原始记录
Q8与十档Q9
→
04 校验计分
合法性 / 个人密度
→
05 评价
聚合 / 分布 / 更新

已经留存

实际消息、原始回答、配置、源码版本、模型回包、token、费用估算、失败与重试。

当前默认

直接报告当期答案。完整概率改动格式有效率不足，未被采用；不自动修复非法概率。

尚需验收

最终提交目录、单一运行入口和干净环境复现。已有日志不等于已经一键交付。

现有流程支持真实LLM实验与离线复算。拟合效果另外通过真实调查和基线模型检验。

本地SocioVerse2流程与真实运行记录。Q9近似计分边界见附录A。

拟合误差的组成与评价指标

分别评价群体中心、家庭差异和逐月变化。各项结果都与同一批真人、同一月份比较。

评价对象	要回答的问题	指标与解释
群体中心	Q9个人密度均值的跨人中位数，按期计算误差再平均	MAE即平均绝对误差，越小越好
跨人分布	不同家庭的预期分布是否接近真人，尾部是否失真	W1为分布差距，越小越好
个人更新	同一个人相对上月的变化，是否过度修正或不更新	变化分布W1；秩相关与分组检查
个人不确定性	一个人给未来不同通胀结果分配概率的宽度与尾部	中间50%的跨度（IQR）、通缩零概率
运行可靠性	是否都能产生可计分回答，失败是否选择性发生	合法率、覆盖率、失败原因与成本

参照：本人上期与个人历史锚；全国长跨度宏观基线另列，不混作同样本对照。

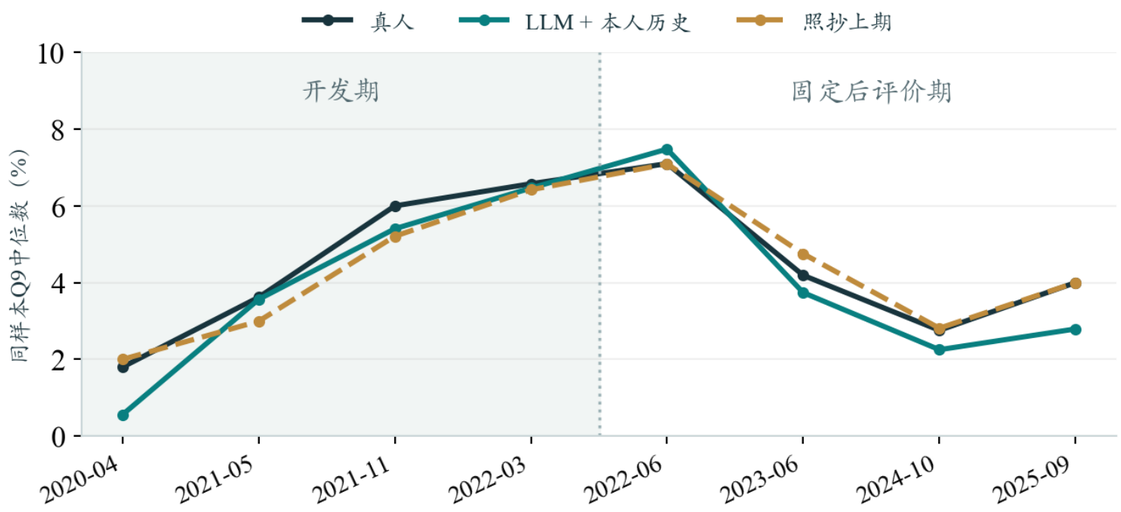
同时检查总体指标和微观分布，才能判断拟合改善来自合理的家庭差异，还是共同水平的移动。

统一计分与经验分位数定义。主结果按月及生成次数等权平均，调查权重结果另作辅助。

八个月模拟结果与基线对比

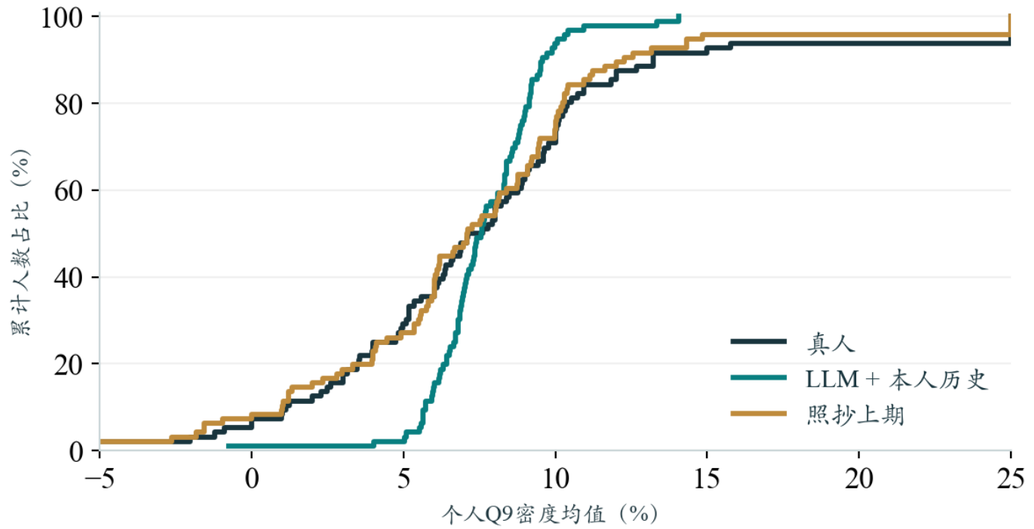
每月96人，两组各生成两次。前四期用于方案选择，后四期用于固定方案后的评价。

八个非连续调查月：同样本Q9中位数



两次生成取均值展示。分界线区分开发与评价，下方误差只使用后四期。

2022-06分布：LLM保留的个人差异偏少



分布展示-5至25%；计分不截尾。2022-06第1次生成、96人。

Q9中心MAE

LLM 0.636 / 照抄 0.156 pp

跨人分布W1

3.161 / 0.691 pp

变化分布W1

1.625 / 2.770 pp

后四期中，LLM的逐月变化分布较好，但群体中心与家庭分布仍差于照抄上期，尚未达到整体目标。

10/14八期实验。误差表仅按后四评价月计算：379个共同人月、757次配对生成，未外推为全国指标。

机制实验与跨模型检查的主要发现

各项结论来自对应批次的内部对照，不能将不同版本的误差直接相减。

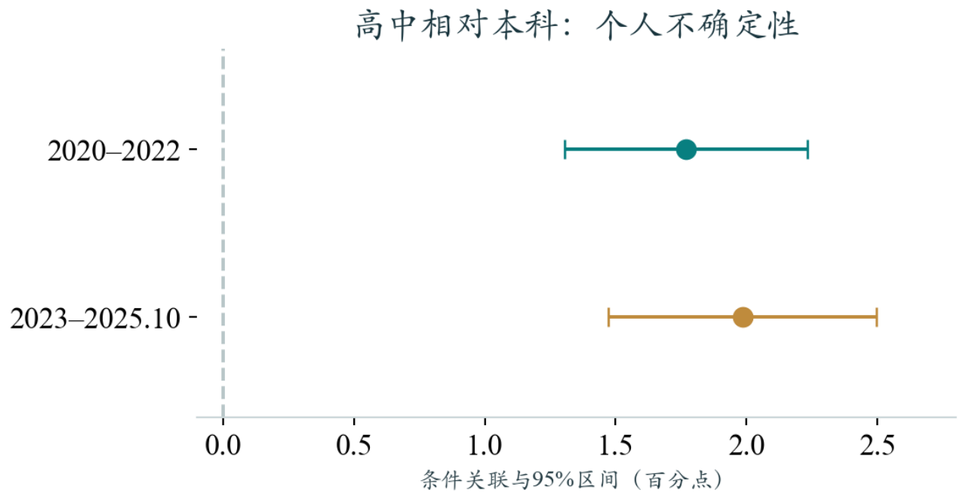
研究内容	观察到的结果	当前处理
本人原有信念	部分实验减小误差、扩大人际差异；仍有向共同中心回缩	保留为输入；更新方式待验
美联储信心标签	相同政策事实下，合成标签有局部收益；跨时期稳定性不足	保留候选，不称普遍有效
新闻与购买频率	个性新闻无稳定增量；频率作用说明未改善总体拟合	修正匹配后再做干净对照
个人历史叙述	加入年龄对应历史数值或文字，未稳定改善	暂缓整段叙述；不否定经验理论
机械概率映射	概率填法更像真人，身份增量很小，分歧未恢复	不作为主要成功机制
相对上期报改动	直接组192/192有效，十档改动组仅118/192有效	保留直接填写本期答案
跨模型与历史知识	DeepSeek/Qwen均偏离SCE，也未稳定贴合一年后实际CPI	拟合偏差不能排除局部记忆，后续做训练边界前后比较

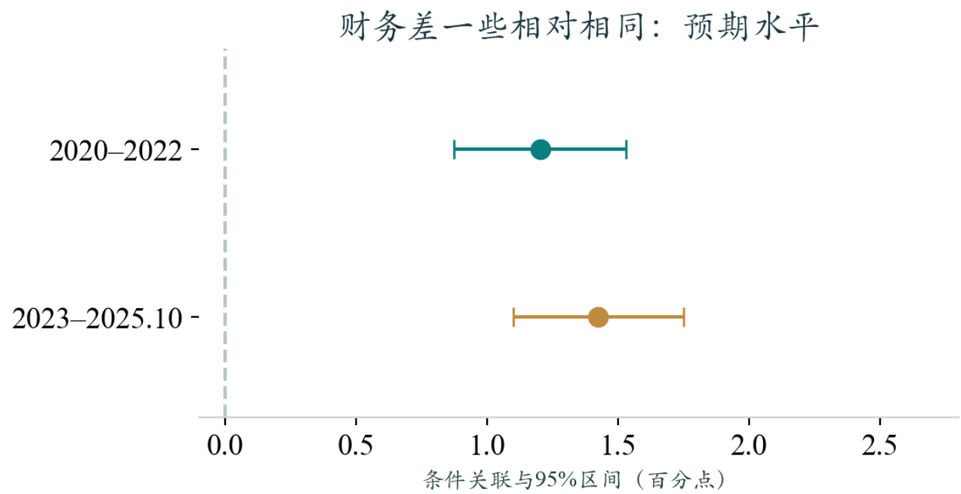
已观察到的改善与未改善结果共同决定后续取舍。理论机制仍需通过具体实现和独立时期检验。

已有实验、2021年DeepSeek/Qwen同消息对照与CPI核查，详细来源见源稿索引，参数与费用见附录B。

认知与财务处境的真实数据依据

70个月、82,535人月：比较月份和其他画像相近的人群，两类关联在前后时期均出现。





认知信息应解释什么

学历和具体认知答法，更稳定地联系个人不确定性；不宜简单翻译成“预测更高通胀”。

财务处境应怎样加入

财务变差与预期较高相关，但存在反向解释；不能把回归系数机械加进每个人的答案。

这些关联为认知与处境的输入设计提供依据。是否能改善LLM模拟，还需在相同P/E下单独检验。

SCE官方派生值。月固定效应、官方权重等月归一、按人聚类。这是条件关联，不能直接解释为因果作用。

后续研究安排与交付计划

优先开展已有数据能够支持、对照关系清楚的研究。每轮只改变一个主要设计。

里程碑	具体行动	继续推进的判据
下一项：认知输入小试	数理高低标签与具体题目 / 本人作答对照，再检验同内容的忠实转述	不提供正确答案或纠错反馈，检查有效率与中心 / 分布误差
并行补齐：人口与价格匹配	维护收入 / 家庭更新；补跨年CE和时间证据；分开合成与实测	先通过离线匹配检查，再决定是否支付新模拟费用
有效后：固定方案再验证	新时期 / 种子、同信息基线、分组误差与日期敏感性	跨期可重复收益才升级；未改善则报告适用边界
交付：可复现研究成果	研究报告、完整运行目录、依赖与来源、实际运行演示	干净环境验收；B递推作为需另验的后续扩展

当前贡献：建立可审计的调查模拟与评价流程，识别模型压缩个体差异的现象，并用对照筛选改进机制。

赛事评分：社会科学价值25%，方法设计25%，结果20%，可复现20%（不及格淘汰），呈现10%。[1]

Q8、Q9与项目计分口径

两题都是未来12个月；Q8点值与Q9密度均值不必相同。

Q8：方向与幅度

先判断总体价格会上涨或下降，再报百分比；项目将其转换成带符号点预期，作为独立辅助结果。

Q9：十个区间的概率

通胀五档：0–2、2–4、4–8、8–12、≥12%；通缩对称五档。原表bin1为通胀≥12%、bin10为通缩≥12%，合计100%。

由回答到统计量

逐人拟合连续密度，再计算个人均值与分位数。全国指标使用调查权重聚合；本报告主实验使用同样本等权中位数，单独注明经验CDF口径。

冻结计分器已做独立月份对照，但Beta分支仍属近似；不称完全复现官方数值实现。

来源：SCE原问卷、FAQ、方法材料及项目冻结计分器；这里区分官方统计与项目近似。[2,7]

用于汇报的关键实验与采用状态

DeepSeek官方API · deepseek-flash · 温度0.5；费用为token估算，非账单，各行不作性能排行。

实验	配置	请求数 / 模拟费	结论与限制
含本人历史 / 不含历史	8期×96人×2组×2次	3,072；约$2.141	未过预设筛选，主要多期证据
历史摘要 / 更新指导	4期×12人×2组×2次	192；约$0.145	摘要有局部收益，指导无明确增量
本人 / 他人上期回答	4期×12人×3组×2次	288；约$0.201	可继续研究，本人特有增量未证实
合成央行信心	4期×48人×2组×2次	768；约$0.495	相同政策事实；标签增量为局部证据
购买频率作用说明	4期×48人×2组×2次	768；约$0.875	两组均有频率，不是有无频率试验
直接 / 十档改动	4期×24人×2组×2次	384；约$0.434	74份非法；完整改动格式不采用

八期另含新闻补标约$0.583；共约$2.725。模拟3072次中3069有效，无自动重试。

完整协议及用量来源见源稿索引；模型别名以回包记录为准，不能据此推断训练截止。

资料发布时间与模型历史知识的核查

已完成历史数值对照，尚未完成能够排除模型参数知识影响的检验。

环节	已有处理	尚未解决 / 未来要求
价格与就业修订	历史输入优先取首发稿；保留观测期、发布日、版本	年度季调等修订不能覆盖原快照；时点缺失则隔离
SCE微观可得性	A使用声明的历史画像与本人旧回答；当期答案仅评价	B不能拿未公布的当期微观样本初始化，需旧人口或合成
新闻与政策事实	按公开时间截断、分类并物化；摘要/片段重复做文本去重	公开不等于本人已读；摘要不能视为完整报道或真实记忆
CE与合成属性	标注跨调查供体、假设与缺失；不伪装为SCE实测	2020供体不全满足早期预测时点；2019/21/22下载仍受阻
模型预训练知识	2021年DeepSeek/Qwen对照均偏离SCE，也未稳定贴合一年后CPI	选训练边界可核验的模型，比较边界前后时期，并用相同P/E控制设计差异

没有稳定复现历史真值，是已有发现。它不足以证明模型完全未使用历史知识，后续将作针对性检验。

数据来源与历史模型对照见源稿索引。未来CPI只作诊断，不用于生成回答或调整参数。

主结果的比较对象与统计口径

主表只比较同一批可评分的人，指标按后四评价月计算。全国长跨度基线另行报告。

比较对象	中心MAE	跨人W1	变化W1	跨人IQR
LLM + 本人历史	0.636	3.161	1.625	1.565
照抄上期	0.156	0.691	2.770	5.291
本人上期值与更早均值各半	0.488	1.052	1.707	5.060
无本人历史的新信息LLM	1.337	4.398	2.933	0.608
对应真人分歧	-	-	-	5.545

样本：4评价月计划384人月，共同可评分379个不同人月、757次生成；378人月两次均有共同支持。各月/重复分别计分，再等权平均。单位均为百分点。

LLM和两条过去信息基线的信息集不同：这里只检验实用表现，不单凭胜负识别因果优势。开发选择的新信号权重为0，程序组合因此等于照抄；未据评价期重新选择。

冻结八期协议、覆盖说明与评价摘要。经验CDF使用左逆定义，区别于插值分位数。

抽样不确定性、失败回答与人口外推

报告区间、有效样本和投影误差，避免把增加生成次数当作增加独立受访者。

误差改善的区间估计

如果改善区间包括0，现有样本仍不能排除平均没有改善。扩大时期与人群覆盖后再检验，重抽样时将同一个人的重复回答保留在一起。

失败必须进入评价

十档改动组只对118/192份合法回答评分，会选择性排除困难样本。因此该批准确度只作条件描述，不作机制增益或成功证据。

Core / Normal人口扩展

少量Core居民由LLM直接作答，再向Normal居民投影以控制成本，投影误差须另外检验。本报告主要机制试验直接调用抽样人群，外推人数不作为新增独立回答。

相同几个月反复调参不能替代独立验证；扩大后需覆盖不同经济阶段与新种子。

评价器与统一比较协议。ConsumerSim提供方法参考，误差不跨研究对象直接比较。[8]

来源与最终交付检查

网页及证据核查截至2026-10-15；完整本地来源索引与聚合数据随源稿留存。

[1] SocioVerse Challenge 2026

socioverse.fudan-disc.com/challenge/ · 赛道A、评分与交付要求

[2] NY Fed SCE FAQ / data

newyorkfed.org/microeconomics/sce · 调查、指标与公开微观材料

[3] D’Acunto et al. (2021), JPE

Exposure to Grocery Prices and Inflation Expectations · doi:10.1086/713192

[4] Malmendier & Nagel (2016), QJE

Learning from Inflation Experiences · 经验学习与代际差异

[5] Armantier et al., NY Fed SR543

The Price Is Right · 随机价格信息与预期更新

[6] Carroll (2003), QJE

Macroeconomic Expectations of Households and Professional Forecasters

[7] Armantier et al. (2017), FRBNY

An Overview of the Survey of Consumer Expectations · 调查方法

[8] ConsumerSim (2026)

arxiv.org/abs/2606.30395 · 人群模拟、投影与统计验证的研究参照

最终交付仍需：4–8页论文、≤5分钟实际运行演示、固定依赖与种子、来源及模型/调用/成本说明、干净环境复现。